

**LAPORAN UJIAN AKHIR SEMESTER  
ANALISIS SINYAL BIOMEDIS**

**KLASIFIKASI AKTIVITAS FISIK BERDASARKAN FITUR HRV DENGAN  
CONVOLUTIONAL NEURAL NETWORKS**



**Oleh :**

Muhammad Reva Alief F.	(082111733006)
Virgo Alifian Wahyu S. W. A. P.	(082111733026)
Syifa Salsabila	(082111733029)
Andi Namira Rachmaninov S.	(082111733039)
Tyara Larasati	(082111733047)
Royhan Zivansyah Lubis	(082111733065)

Dosen Pembina:

Dr. Riries Rulaningtyas, S. T., M. T.

**PROGRAM STUDI S1 TEKNIK BIOMEDIS  
DEPARTEMEN FISIKA  
FAKULTAS SAINS DAN TEKNOLOGI  
UNIVERSITAS AIRLANGGA**

**2024**

# **BAB I**

## **PENDAHULUAN**

### **1.1. Latar Belakang**

Pada tahun 2019, diberitakan bahwa terdapat seorang atlet triathlon bernama Kate Allen mengalami kejadian yang menegangkan saat berlomba di Ironman World Championship di Hawaii. Saat berenang, dia merasakan sakit dada yang parah dan pingsan. Untungnya, tim medis dengan sigap mengevakuasi dan memberikan pertolongan darurat. Setelah pulih, Allen menjalani berbagai pemeriksaan, termasuk analisis variabilitas detak jantung (HRV). Hasilnya menunjukkan bahwa HRV Allen meningkat secara signifikan selama berminggu-minggu sebelum kejadian. Hal ini merupakan tanda peringatan dini gagal jantung (Rogers *et al.*, 2022).

Berdasarkan temuan ini, Allen didiagnosis dengan miokarditis, peradangan otot jantung yang dapat berakibat fatal jika tidak diobati. Berkat deteksi dini melalui HRV, Allen menerima pengobatan yang tepat dan pulih sepenuhnya. Dia bahkan kembali berkompetisi di triathlon dan menjadi juara dunia Ironman 70.3 pada tahun 2021.

Melalui kasus yang dialami Kate Allen menjadi contoh nyata bahwa besar peningkatan HRV pada seseorang, khususnya para atlet sangat krusial sebagai tanda peringatan dini adanya masalah kesehatan jantung. Pemantauan HRV secara rutin dapat membantu mengidentifikasi risiko potensial dan mencegah kejadian yang fatal dan dapat diambil langkah-langkah pencegahan.

Variabilitas detak jantung atau Heart Rate Variability (HRV) ini tidak hanya perlu dilakukan pemantauan pada para atlet, melainkan pada semua orang. Pada orang biasa, besar nilai HRV dapat dipengaruhi oleh beberapa faktor, seperti usia, kondisi kesehatan, dan gaya hidup. Gaya hidup seseorang dapat dikategorikan menjadi dua, yaitu gaya hidup aktif dimana seseorang secara fisik aktif dan rutin menggerakkan anggota tubuhnya dan gaya hidup tidak aktif dimana keterbalikan dari gaya hidup aktif. Gaya hidup sehat yang disarankan adalah gaya hidup aktif dengan melakukan olahraga secara rutin, seperti berlari. Melalui kegiatan ini, HRV seseorang dapat dipantau secara berkala.

Pemantauan besar nilai HRV seseorang dapat dilakukan melalui kegiatan sederhana seperti berlari dan saat istirahat (Stahl *et al.*, 2016; Manser *et al.*, 2021). Dimana pada saat

seseorang berlari, secara umum akan meningkatkan nilai HRV karena dengan berlari akan memicu sistem saraf simpatik yang meningkatkan detak jantung dan variabilitasnya. HRV akan kembali turun atau ke tingkat yang normal setelah beberapa jam bersamaan dengan kelelahan otot. Begitu pula dalam keadaan istirahat atau relaksasi secara umum akan meningkatkan nilai HRV dalam jangka panjang. Hal ini karena kegiatan relaksasi akan memicu sistem saraf parasimpatis dengan menurunkan detak jantung dalam waktu yang lama dan hal ini akan meningkatkan variabilitasnya. Melalui relaksasi pula telah menjaga nilai HRV untuk tetap stabil.

Pemantauan nilai HRV seseorang didapati melalui perhitungan metode R-R interval, yaitu dengan mengukur interval waktu antara dua puncak detak jantung (R-R interval) secara manual dengan alat elektrokardiogram (EKG) atau stetoskop (Choi et al., 2010). Seiring perkembangan teknologi, pemantauan nilai HRV dapat dilakukan dengan bantuan perangkat yang mudah diakses oleh tiap orang. Penggunaan *smartwatch* menjadi perangkat yang telah banyak dimiliki oleh masyarakat saat ini. Meskipun menawarkan banyak manfaat untuk memantau kesehatan, termasuk nilai HRV, *smartwatch* kerap menunjukkan beberapa kekurangan yang perlu dipertimbangkan dalam pemantauan nilai HRV. Beberapa kekurangan ini, antara lain akurasi sensor yang kurang akurat terutama dalam algoritma perhitungan dan fitur yang ditawarkan dalam pemantauan nilai HRV yang kurang komprehensif.

Melalui urgensi dari pemantauan nilai HRV secara berkala, diperlukannya sebuah perangkat yang dapat menangkap sinyal jantung dan mengkalkulasikan menjadi nilai HRV. Stetoskop adalah perangkat diagnostik yang telah lama digunakan dalam bidang medis dimana memungkinkan dokter untuk mengamati suara jantung dalam mendeteksi abnormalitas jantung. Inovasi terbaru dalam pengembangan perangkat ini adalah penerapan sensor detak jantung yang terintegrasi menjadi solusi dalam penilaian besar HRV seseorang.

Oleh karena itu, untuk mewujudkan perangkat tersebut, dirancanglah sebuah sistem deteksi besar nilai HRV seseorang. Melalui nilai tersebut dapat diklasifikasikan bahwa seseorang sedang dalam keadaan rileks (duduk) dan beraktivitas (lari). Data yang diperoleh adalah variasi heart rate (HR) dari naracoba yang kemudian diolah melalui software Google Collaboratory. Sistem deteksi ini diharapkan dapat dimanfaatkan masyarakat dalam pemantauan nilai HRV demi menjaga kesehatan jantung, meningkatkan efektivitas kegiatan seperti berolahraga, dan mengoptimalkan performa bagi para atlet.

## **1.2. Rumusan Masalah**

- a. Pada frekuensi berapa saja yang harus difilter supaya meminimalkan noise yang ada pada data mentah Heart Rate Variability?
- b. Fitur HRV apa saja yang perlu diekstraksi dari data mentah HRV?
- c. Sejauh mana penggunaan metode analisis domain waktu, frekuensi, dan nonlinier dapat mengklasifikasi HRV saat kondisi rileks (duduk) dan beraktivitas (lari) ?

## **1.3. Tujuan Penelitian**

- a. Menentukan frekuensi yang harus difilter guna meminimalkan noise pada data mentah heart rate variability (HRV).
- b. Mengidentifikasi fitur-fitur HRV yang perlu diekstraksi dari data mentah HRV.
- c. Mengevaluasi sejauh mana metode analisis domain waktu, frekuensi, dan nonlinier dapat mengklasifikasi HRV dalam kondisi relaks (duduk) dan saat beraktivitas (lari).

## **1.4 Manfaat Penelitian**

Dapat digunakan sebagai bekal awal dalam melakukan pengembangan teknologi dan pemrograman yang lebih canggih untuk merancang program latihan yang lebih disesuaikan dengan kebutuhan individu, meningkatkan efektivitas latihan, dan mengoptimalkan performa.

## **BAB II**

### **TINJAUAN PUSTAKA**

#### **2.1. Definisi HRV dan Signifikansinya**

Variabilitas detak jantung (HRV) adalah variasi detak jantung di antara rangkaian interval R-R. Variasi ini tidak hanya dipengaruhi oleh proses fisiologis seperti respirasi atau laju metabolisme, tetapi juga secara langsung dikontrol oleh sistem saraf otonom (Peabody, 2023). HRV juga didefinisikan sebagai variasi fisiologis dalam durasi interval antara denyut sinus dengan mencerminkan aktivitas gabungan dari tonus simpatis dan parasimpatis pada HR dan berfungsi sebagai indikator yang terukur dari integritas dan prognosis kardiovaskular. Kriteria formal untuk HRV dan perbandingan variabel dikembangkan oleh kelompok kerja bersama antara European Society of Cardiology dan North American Society of Pacing and Electrophysiology pada tahun 1996 dan diperbarui pada tahun 2015 (Sassi, 2015). Pembaruan ini menambahkan metode yang lebih baru, termasuk analisis fraktal dan kekacauan, serta menyoroti keterkaitan antara perkembangan teknik biomedis dan penerapannya pada kondisi penyakit klinis. Metode analisis utama dapat dibagi menjadi domain waktu (dibagi lagi menjadi pendekatan statistik dan geometris) dan metode domain frekuensi.

Mendukung pentingnya sistem saraf otonom (ANS) dalam hal kesehatan dan prognosis kardiovaskular (Freeman, 2005). ANS sebagian besar merupakan sistem eferen yang mentransmisikan impuls dari sistem saraf pusat (SSP) ke organ perifer. Efeknya meliputi kontrol HR dan kekuatan kontraksi jantung, penyempitan dan dilatasi pembuluh darah, kontraksi dan relaksasi otot polos di berbagai organ, dan sekresi kelenjar. Variabel spesifik yang berasal dari detak jantung (HR) dan variabilitas detak jantung (HRV) saat istirahat dan saat berolahraga dapat membantu menilai status ANS. Minat juga memuncak pada penggunaan HRV untuk menilai kualitas program latihan.

Di antara populasi atletik, HRV telah direkomendasikan untuk memperingatkan latihan yang berlebihan dan untuk mengoptimalkan kinerja. Dalam dunia medis adanya ketersediaan yang luas dari tim Health perangkat pemantauan SDM (perangkat kesehatan dan medis) untuk status kesehatan dan penilaian latihan olahraga memberikan motivasi untuk tinjauan sistematis ini (Eapen, 2015). Penggunaan parameter pengukuran HRV dapat mempermudah terapis untuk mengatur porsi latihan dari para atlet untuk mencapai kapasitas maksimalnya.

## 2.2. Metode Pengukuran HRV

Pengukuran HRV dapat dilakukan dengan berbagai cara pengukuran sebagai topik analisis diantaranya domain waktu, frekuensi dan geometrik. Domain waktu mengukur HRV selama interval waktu antara siklus jantung normal. Hal ini biasanya diukur dengan menghitung waktu antara gelombang q yang berurutan pada elektrokardiogram (EKG). Dalam banyak literatur, nilai ini direpresentasikan sebagai rata-rata interval normal-ke-normal (N-N). Untuk analisis statistik, standar deviasi dari nilai rata-rata interval N-N digunakan (SDNN). Ketika melihat nilai numerik SDNN dan hubungannya dengan HRV, semakin besar SDNN, semakin besar pula HRV. Seperti yang dinyatakan sebelumnya, semakin besar HRV, semakin besar pengaruh *parasympathetic nervous system* terhadap otomatisitas jantung. Nilai waktu umum lainnya yang digunakan dalam analisis adalah root mean square of the successive differences (RMSSD). Nilai ini menilai akar kuadrat rata-rata dari proporsi interval N-N yang lebih besar dari 50 ms terhadap jumlah total interval N-N. RMSSD mewakili PNS, dan RMSSD yang lebih besar sesuai dengan peningkatan HRV (Petrowski, 2019).

HRV dapat dianalisis juga dari domain frekuensi, dimana data mengkuantifikasi kontribusi dari masing-masing saraf simpatis dan parasimpatis. Istilah yang digunakan untuk menggambarkan analisis HRV dalam domain frekuensi adalah power spectral density (PSD). Pada awal, fenomena fisiologis yang dikenal sebagai aritmia sinus pernapasan (RSA) terjadi, yang menghasilkan variasi interval R-R yang diciptakan oleh siklus pernapasan.

Efek parasimpatis vagal memperlambat denyut jantung selama ekspirasi, menciptakan lebih banyak variasi (sesuai dengan fenomena ketergantungan panjang siklus yang dijelaskan di atas). Selama inspirasi, dorongan vagal berkurang, mengakhiri RSA. Pita frekuensi tinggi (HF) (0,15-0,40 Hz) menangkap RSA yang dihasilkan dari stimulasi vagal PNS baik dari interaksi pusat maupun refleksi. Pita frekuensi rendah (LF) (0,04-0,15 Hz) menangkap informasi selama inspirasi, di mana stimulasi vagal cardioinhibitory dihambat (Zenati, 2019). Selanjutnya yaitu metode pengukuran HRV menggunakan domain geometrik. Domain geometris diwakili oleh indeks segitiga variabilitas denyut jantung (HTI). Ukuran ini menghitung integral dari densitas histogram interval R-R dibagi dengan tingginya. Periode lima menit biasanya digunakan untuk mewakili metrik ini.

### **2.3. Aplikasi HRV dalam Berbagai Konteks**

HRV merupakan parameter penting untuk menilai kesehatan, kebugaran, dan kebugaran personel taktis secara keseluruhan (Bota, 2019). Beban latihan dipengaruhi oleh intensitas dan dampak fisiologis latihan, yang diwakili oleh perubahan HRV selama latihan dan pemulihan. HRV juga dipengaruhi oleh beban kognitif, stres fisiologis dan emosional, dan lingkungan. Dalam pemantauan jangka panjang, ini adalah metode non-invasif untuk menilai sistem saraf autonom dan membuat perubahan yang tepat untuk pelatihan dan pemulihan (Makivić, 2013). Dalam pemantauan jangka pendek, HRV berguna dalam menilai respons terhadap rangsangan akut, seperti peristiwa pelatihan fisik atau kognitif. Karena, usia, posisi tubuh, dan waktu dalam sehari semuanya mempengaruhi pengukuran HRV (Vitale, 2019). HRV harus sangat individual dan dinilai relatif terhadap individu. Secara statistik, periode waktu sebelum, selama, dan setelah aktivitas dibandingkan antara satu dengan yang lain (dan sebagai delta dari garis dasar yang akurat atau rata-rata bergulir) untuk menentukan modulasi sumber daya dalam kaitannya dengan kinerja tugas.

### **2.4. Teknologi dan Alat untuk Pengukuran HRV**

Pengukuran HRV melibatkan penggunaan teknologi canggih seperti sensor wearable dan software analisis data yang inovatif. Sensor wearable yang umum digunakan mencakup elektrokardiogram (ECG), yang mengukur aktivitas listrik jantung dengan presisi tinggi, dan photoplethysmography (PPG), yang mengukur perubahan volume darah di pembuluh darah menggunakan cahaya. Contoh perangkat wearable yang menggunakan teknologi ini termasuk Smartwatch, yang menggunakan PPG untuk mengukur HRV melalui aplikasi Health, serta Whoop Strap dan Oura Ring, yang menawarkan analisis mendalam mengenai HRV dan kondisi fisik pengguna (Shaffer et al., 2014).

Selain perangkat wearable, software untuk analisis data HRV memainkan peran penting dalam memberikan wawasan yang lebih mendalam. Aplikasi seperti Kubios HRV dan Elite HRV menyediakan analisis HRV yang komprehensif, termasuk analisis frekuensi dan non-linear. Kubios HRV, misalnya, adalah aplikasi desktop yang populer di kalangan peneliti untuk analisis HRV yang mendalam, sedangkan Elite HRV menawarkan analisis HRV bagi pengguna individu, pelatih, dan profesional kesehatan. Fitur analisis yang umum meliputi time-domain analysis, frequency-domain analysis, dan non-linear analysis, yang masing-masing memberikan informasi berharga tentang kondisi jantung dan kesejahteraan

secara keseluruhan (Tarvainen & Niskanen, 2008). Teknologi pengukuran HRV terus berkembang, menawarkan lebih banyak peluang untuk aplikasi dalam kesehatan pribadi dan profesional, dengan sensor wearable dan software analisis yang menjadi lebih akurat dan mudah diakses oleh pengguna (Malik & Camm, 1995).

## **2.5. Faktor-Faktor yang Mempengaruhi HRV**

Heart Rate Variability (HRV) dipengaruhi oleh berbagai faktor seperti usia, jenis kelamin, kondisi kesehatan, dan aktivitas fisik. Faktor-faktor ini dapat mempengaruhi sistem saraf otonom yang mengatur detak jantung, sehingga berdampak pada hasil pengukuran HRV. HRV cenderung menurun seiring bertambahnya usia. Pada individu yang lebih muda, sistem saraf otonom lebih responsif, memungkinkan variasi yang lebih besar dalam interval antara detak jantung. Sebaliknya, pada individu yang lebih tua, respons sistem saraf terhadap berbagai rangsangan berkurang, yang menyebabkan penurunan variabilitas detak jantung. Penurunan HRV dengan usia mencerminkan penurunan kemampuan adaptasi tubuh terhadap stres dan perubahan lingkungan (Umetani et al., 1998).

Jenis kelamin juga mempengaruhi HRV. Umumnya, perempuan memiliki HRV yang lebih rendah dibandingkan laki-laki, terutama sebelum menopause. Hal ini kemungkinan disebabkan oleh perbedaan hormonal, seperti pengaruh estrogen dan progesteron, yang mempengaruhi sistem saraf otonom. Setelah menopause, perbedaan HRV antara laki-laki dan perempuan cenderung mengecil (Bigger et al., 1995). Kondisi kesehatan sangat berpengaruh pada HRV. Penyakit kronis seperti diabetes, hipertensi, dan penyakit jantung dapat menurunkan HRV karena gangguan pada fungsi saraf otonom dan peningkatan stres fisik serta emosional. Selain itu, kondisi psikologis seperti stres, kecemasan, dan depresi juga dapat mengurangi HRV dengan meningkatkan aktivitas saraf simpatis dan menurunkan aktivitas saraf parasimpatis (Thayer et al., 2010). Aktivitas fisik memiliki dampak signifikan pada HRV. Latihan fisik teratur biasanya meningkatkan HRV dengan meningkatkan tonus vagal dan menurunkan aktivitas simpatis. Atlet, misalnya, sering menunjukkan HRV yang lebih tinggi dibandingkan dengan individu yang tidak aktif, yang mencerminkan tingkat kebugaran kardiovaskular yang lebih baik dan kemampuan tubuh untuk beradaptasi dengan stres fisik (Aubert et al., 2003).



## BAB III

### METODE PENELITIAN

#### 3.1. Waktu dan Tempat Penelitian

Waktu dan tempat penelitian pada pengambilan data Heart Rate pada jantung dilaksanakan pada Kamis, 14 Maret 2024 di Laboratorium Teknik Biomedis untuk data Rest Heart Rate (RHR) dan Selasa, 19 Maret 2024 di area SC FST untuk pengambilan data Heart Rate Activity (HRA) setelah *jogging*.

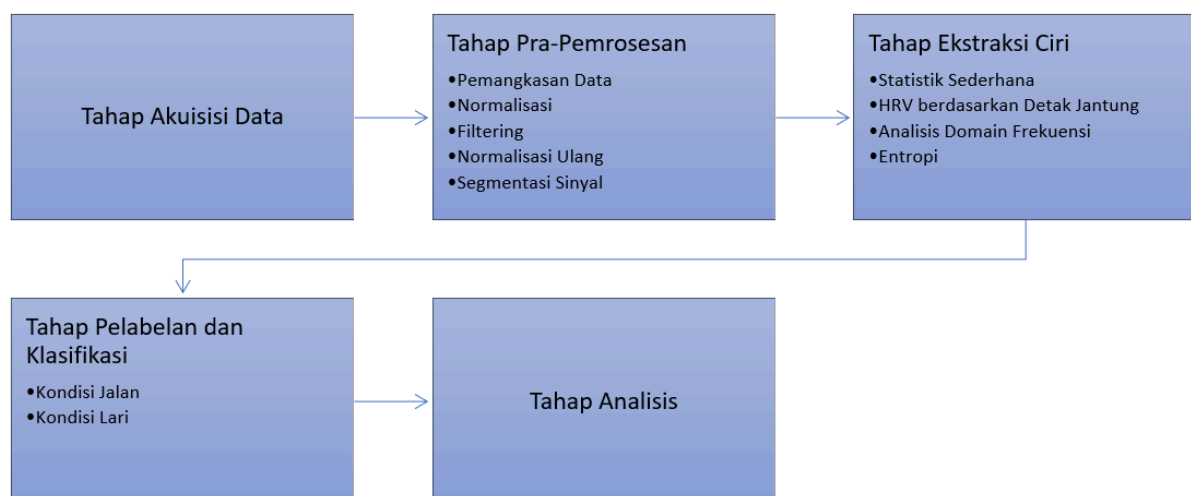
#### 3.2. Alat dan Bahan

Alat dan bahan yang diperlukan pada penelitian ini, antara lain:

1. Laptop ASUS ROG Windows 10 RAM 16 GB
2. Software PuTTY
3. Software Google Colaboratory
4. Stetoskop Digital
5. Stopwatch

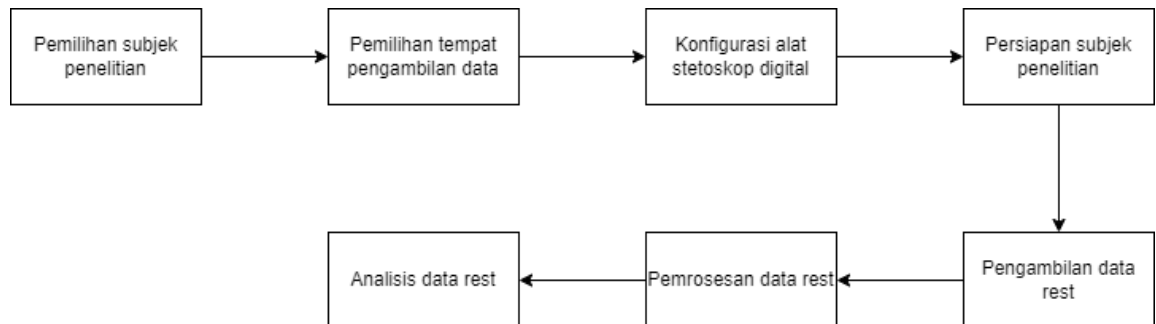
#### 3.3. Prosedur Penelitian

Prosedur penelitian dilaksanakan dengan melalui runtutan kegiatan sebagaimana terangkum melalui skema prosedur di bawah ini:



### 3.3.1. Tahap Akuisisi Data

Pada prosedur pengambilan Rest Heart Rate (RHR), naracoba sedang tidak melakukan aktivitas. Naracoba diminta untuk memposisikan dirinya tegap dan tidak banyak bergerak selama pengambilan data. Hal ini bertujuan untuk mengurangi nilai noise yang terjadi akibat pergeseran dan pergerakan sendi ataupun benda yang ikut terkena gesekan. Berikut diagram pengambilan data RHR,



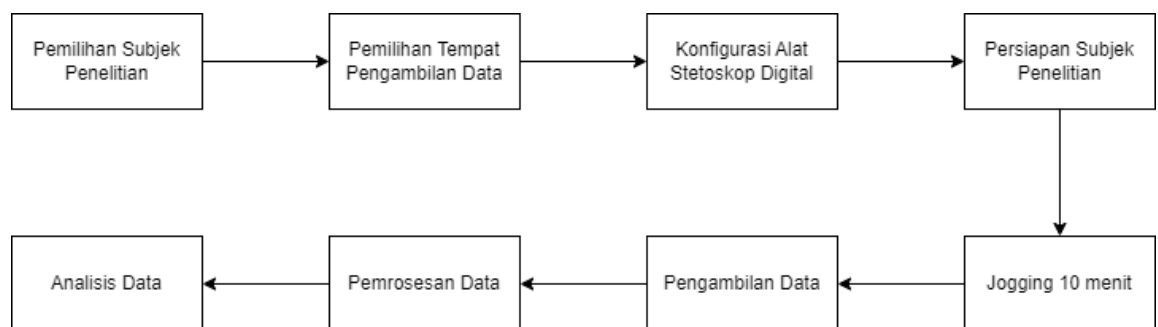
Gambar 3.3.1 Diagram Prosedur Pengambilan Data RHR

Secara lengkap, prosedur ini dilakukan dengan cara sebagai berikut:

1. Pastikan pengambilan data dilakukan di ruang tertutup yang kedap suara
2. Pastikan naracoba sedang dalam keadaan yang tenang, santai, rileks. Berikan kesempatan pada naracoba 5-13 menit untuk meditasi dan menenangkan diri sambil mendengarkan musik relaksasi. Upayakan naracoba tidak dalam keadaan lelah, panik, atau takut.
3. Pengambilan data dilakukan setelah naracoba benar-benar tenang. Pengambilan data menggunakan stetoskop digital dilakukan dengan posisi naracoba duduk di kursi sambil diukur nilai HR nya menggunakan alat dengan langsung menyentuh kulit dada dari naracoba.
4. Selama pengambilan data HR, naracoba tetap dalam keadaan rileks sambil bernapas normal, tidak ada inspirasi dan ekspirasi maksimum yang diperkenankan untuk dilaksanakan oleh naracoba. Selain itu, naracoba juga dilarang untuk berbicara selama proses pengambilan data dilaksanakan agar tidak menimbulkan noise pada data.

5. Pengambilan data dilaksanakan selama 1 menit 30 detik, dengan rincian 15 detik pertama untuk stabilisasi alat, 1 menit berikutnya untuk pengukuran denyut jantung, lalu 15 detik terakhir untuk stabilisasi.
6. Pengambilan data dilakukan menggunakan software putty, kemudian file disimpan di folder pada link di bawah ini dengan format **RHR\_Nama.csv**  
[https://drive.google.com/drive/folders/1h3eW70aHHsHt\\_WEWtDlja-cmIIZxKTs?usp=sharing](https://drive.google.com/drive/folders/1h3eW70aHHsHt_WEWtDlja-cmIIZxKTs?usp=sharing)

Selanjutnya, dilakukan pengambilan data Heart Rate After Activity (HRA) pada naracoba. Pada prosedur ini, naracoba diminta untuk melakukan aktivitas olahraga, dimana pada penelitian ini dilakukan jogging. Berikut diagram pengambilan data HRA,



Gambar 3.3.3 Diagram Prosedur Pengambilan Data HRA

Secara lengkap, prosedur ini dilakukan dengan cara sebagai berikut:

1. Setelah naracoba diambil datanya pada saat kondisi rileks, selanjutnya naracoba diminta untuk berlari jogging selama 10 menit untuk mengetahui berapa nilai HRA-nya.
2. Setelah 10 menit jogging, naracoba langsung diukur detak jantungnya menggunakan stetoskop digital. Sebelumnya pastikan membersihkan area kulit dada yang hendak digunakan untuk mengukur heart rate dari keringat menggunakan tissue.
3. Pengambilan data menggunakan stetoskop digital dilakukan dengan posisi naracoba duduk di kursi sambil diukur nilai HR nya menggunakan alat dengan langsung menyentuh kulit dada dari naracoba.
4. Selama pengambilan data HR, naracoba dilarang untuk berbicara agar tidak menimbulkan noise pada data.

5. Pengambilan data dilaksanakan selama 1 menit 30 detik, dengan rincian 15 detik pertama untuk stabilisasi alat, 1 menit berikutnya untuk pengukuran denyut jantung, lalu 15 detik terakhir untuk stabilisasi.
6. Pengambilan data dilakukan menggunakan software putty, kemudian file disimpan di folder pada link di bawah ini dengan format **HRA\_Nama.csv**  
[https://drive.google.com/drive/folders/1h3eW70aHHsHt\\_WEWttDlja-cmIIZxKTs?usp=sharing](https://drive.google.com/drive/folders/1h3eW70aHHsHt_WEWttDlja-cmIIZxKTs?usp=sharing)

### 3.3.2. Tahap Pra-Pemrosesan

Pada tahapan ini, dilakukan pra-pengolahan data dengan melakukan pemangkasan, normalisasi, dan filtering untuk data sinyal yang hendak diolah supaya memudahkan dalam proses ekstraksi ciri dari data tersebut. Berikut dijelaskan dengan lebih detail terkait tahapan-tahapan pra-pemrosesan dalam proyek kali ini:

#### 3.3.2.1. Pemangkasan Data (*Data Truncation*)

Tahap pemangkasan data atau *data truncation* dilakukan dengan cara melakukan pemotongan data pada awal atau akhir durasi untuk menghilangkan bagian yang tidak diinginkan atau untuk menyesuaikan panjang data dari sinyal yang diambil. Data penting dari sinyal yang telah dipangkas diperlukan dari data yang utuh dengan tujuan untuk mengidentifikasi dan memisahkan bagian-bagian penting dari sinyal. Proses pemangkasan ini dilakukan untuk memperoleh informasi yang relevan dari sinyal yang dapat digunakan untuk mengklasifikasi aktivitas fisik yang berbeda yang dilakukan oleh naracoba.

Pada proyek ini dilakukan proses pemangkasan dari sinyal denyut jantung mentah dengan durasi 90 detik. Pemangkasan dilakukan dengan hanya mengambil durasi sepanjang 60 detik dari keseluruhan durasi data, yaitu pada posisi 15 detik setelah durasi stabilisasi dan 15 detik sebelum pengambilan sinyal selesai.

Data sinyal tersebut memiliki format CSV dengan frekuensi sampling sebesar 200 Hz sehingga total data yang diambil pada proses pengambilan data adalah sekitar 18.000 data dalam kurun waktu 90 detik. Dengan mempertimbangkan ketentuan tersebut, maka data sinyal yang diambil adalah data ke-3001 hingga data ke-15.000. Proses pemangkasan ini dilakukan secara manual

menggunakan Ms. Excel dengan mengeliminasi data ke-1 hingga data ke-3000 serta mengeliminasi data ke-15.001 hingga data ke-18.000. Setelah proses eliminasi dilaksanakan, data yang masih berformat CSV dikonversi ke dalam format TXT, untuk selanjutnya difilter dengan menggunakan software Google Colaboratory. Kemudian file disimpan di folder pada link di bawah ini dengan format **RHR\_Nama\_Cuttetd.txt** dan **HRA\_Nama\_Cuttetd.txt**.  
<https://drive.google.com/drive/folders/1kS7hvjZiMQetz1CJxZhAs8PUdPrN36y?usp=sharing>

### 3.3.2.2 Normalisasi Data

Setelah pemangkasan bagian yang tidak diperlukan, data kemudian diimport pada program lalu dilaksanakan proses normalisasi data sinyal denyut jantung. Normalisasi adalah proses mengubah nilai-nilai dalam dataset menjadi skala umum tanpa mengubah perbedaan antara rentang nilai. Dalam konteks sinyal detak jantung, normalisasi membantu menghilangkan perbedaan skala yang mungkin ada antara berbagai rekaman sinyal yang diambil dari subjek yang berbeda. Dengan melakukan normalisasi, kita memastikan bahwa semua sinyal berada pada skala yang sama, yaitu antara 0 dan 1, yang memudahkan analisis lebih lanjut.

Persamaan untuk normalisasi adalah sebagai berikut:

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

$x_{norm}$  adalah nilai sinyal yang telah dinormalisasi,

$x$  adalah nilai asli dari sinyal,

$x_{min}$  adalah nilai minimum dari sinyal asli,

$x_{max}$  adalah nilai maksimum dari sinyal asli.

Proses ini mengubah setiap nilai  $x$  dalam sinyal menjadi nilai dalam rentang 0 hingga 1 berdasarkan nilai minimum dan maksimum dari sinyal tersebut. Langkah ini dilakukan dengan mengurangi nilai minimum dari setiap nilai dalam sinyal, kemudian membaginya dengan rentang (nilai maksimum dikurangi nilai minimum).

### 3.3.2.3 Filtering

Proses filtering pada sinyal dilakukan dengan tujuan untuk membersihkan sinyal dari berbagai *noise* atau gangguan yang tidak diinginkan serta untuk menyoroti informasi yang penting dalam sinyal tersebut. Selain itu, harapannya dengan melakukan proses filtering dapat menjadikan informasi yang relevan dalam sinyal bisa dipertahankan sedangkan *noise* dapat diminimalkan. Proses filtering sinyal dilakukan dengan menggunakan bandpass filter, highpass filter, dan bandstop filter. Ketiga filter ini dirancang menggunakan filter Butterworth yang memiliki respons frekuensi yang halus dan tidak memiliki ripple dalam passband.

Proses filter butterworth dalam meredam atau melewati komponen frekuensi yang berbeda dari sebuah sinyal digambarkan melalui fungsi transfernya. Filter Butterworth dikenal dengan respon frekuensinya yang datar di daerah passband, artinya tidak ada riak, sehingga ideal untuk banyak aplikasi di mana respon yang mulus diperlukan. Bentuk umum fungsi transfer untuk filter Butterworth dapat diberikan sebagai berikut:

$$|H(j\omega)|^2 = \frac{1}{1 + \left(\frac{\omega}{\omega_c}\right)^{2n}}$$

$H(j\omega)$ : respon frekuensi

$\omega$  : frekuensi dari sinyal input.

$\omega_c$  : frekuensi cutoff dari filter

$n$  : orde filter

#### a. Bandpass Filter

Bandpass filter adalah jenis filter yang memungkinkan frekuensi dalam rentang tertentu untuk melewati dan menahan frekuensi di luar rentang tersebut. Bandpass filter diterapkan menggunakan jenis filter Butterworth dengan orde filter sebesar 4. Orde filter menentukan seberapa tajam transisi antara frekuensi yang difilter dan frekuensi yang dilewatkan. Parameter dari bandpass filter adalah frekuensi *cut off* rendah ( $F_l$ ) yang ditetapkan pada 1 Hz dan frekuensi *cut off* tinggi ( $F_h$ ) yang ditetapkan pada 53 Hz. Rentang

frekuensi yang akan dilewatkan oleh filter ditentukan oleh frekuensi *cut off* rendah dan tinggi ini. Filter Butterworth digunakan dalam bandpass filtering. Filter Butterworth digunakan dalam band-pass filtering. Proses filtering ini dilakukan dalam tiga langkah, yaitu menghitung frekuensi normalisasi, membangun koefisien filter, dan menerapkan filter pada data.

Frekuensi normalisasi dihitung dengan membagi frekuensi cutoff dengan frekuensi Nyquist. Frekuensi Nyquist adalah setengah dari frekuensi sampling (fs).

$$low = \frac{lowcut}{nyq}, \quad high = \frac{highcut}{nyq}$$

di mana:

- lowcut = 1 Hz
- highcut = 53 Hz
- nyq =  $0.5 \times 200 \text{ Hz} = 100 \text{ Hz}$

Koefisien filter dibangun menggunakan fungsi **butter** untuk mendesain filter Butterworth orde 4.

**b,a=butter(order, [low, high], btype='band')**

Filter diterapkan dengan menggunakan fungsi **filtfilt** untuk menerapkan filter dua arah, sehingga menghindari pergeseran fasa.

**bandpass\_data=filtfilt(b,a,normalized\_data)**

## **b. Highpass Filter**

Highpass filter digunakan untuk melewatkan sinyal dengan frekuensi di atas nilai cut-off tertentu, sementara memblokir atau meredam sinyal dengan frekuensi di bawah nilai cut-off tersebut. Filter ini berguna untuk menghilangkan komponen rendah seperti baseline drift atau komponen DC dari sinyal biomedis atau sinyal lain yang tidak diinginkan. Dalam implementasinya, filter highpass mengoperasikan prinsip matematis yang melibatkan perhitungan frekuensi cut-off relatif terhadap frekuensi sampling

data. Frekuensi cut-off merupakan titik di mana respons filter mulai meredam sinyal di bawahnya. Proses ini dimulai dengan normalisasi frekuensi cut-off ke dalam domain digital, yang kemudian digunakan untuk menghitung koefisien filter. Butterworth filter sering digunakan dalam aplikasi ini karena memberikan respons frekuensi yang datar di band pass-nya, dan orde filter (order) menentukan seberapa tajam filter dalam memblokir frekuensi yang tidak diinginkan. Dalam kode yang diberikan, filter highpass diimplementasikan dengan menggunakan nilai cutoff sebesar 20 Hz dengan orde sebesar 4. Semakin tinggi orde filter, semakin tajam respons frekuensi filternya, tetapi bisa juga menyebabkan distorsi pada sinyal. Order yang lebih rendah memberikan respons yang lebih halus tetapi mungkin kurang efektif dalam meredam frekuensi di bawah cut-off.

Frekuensi normalisasi dihitung dengan membagi frekuensi cutoff dengan frekuensi Nyquist. Frekuensi Nyquist adalah setengah dari frekuensi sampling (fs).

$$normal\ cutoff = \frac{cutoff}{nyq}$$

di mana:

- $cutoff = 20\text{ Hz}$
- $nyq = 0.5 \times 200\text{ Hz} = 100\text{ Hz}$

Koefisien filter dibangun menggunakan fungsi **butter** untuk mendesain filter Butterworth orde 4.

**b,a=butter(order, normal\_cutoff, btype='high')**

Filter diterapkan dengan menggunakan fungsi **filtfilt** untuk menerapkan filter dua arah, sehingga menghindari pergeseran fasa.

**highpass\_data=filtfilt(b,a,bandpass\_data)**

### c. Bandstop Filter



Bandstop filter digunakan untuk menghilangkan atau menekan sinyal pada frekuensi tertentu, yang dalam konteks ini dimaksudkan untuk mengurangi *noise* atau interferensi yang dapat berasal dari sumber-sumber listrik atau interferensi lainnya. Proses penerapan bandstop filter dilakukan setelah high pass filter menggunakan jenis filter butterworth. Frekuensi rendah dan tinggi dari bandstop Filter ditetapkan pada 49 Hz dan 51 Hz dengan orde filter yang dipakai adalah orde 4. Hal ini mengindikasikan bahwa filter akan menekan atau menghilangkan sinyal yang berada dalam rentang frekuensi ini, terutama menekan frekuensi 50 Hz dikarenakan setelah sinyal ditampilkan dalam domain frekuensi terdapat sinyal *noise* yang cukup mengganggu pada frekuensi 50 Hz yang mana hal ini perlu untuk ditekan.

Frekuensi normalisasi dihitung dengan membagi frekuensi cutoff dengan frekuensi Nyquist. Frekuensi Nyquist adalah setengah dari frekuensi sampling (*fs*).

$$low = \frac{lowcut}{nyq}, \quad high = \frac{highcut}{nyq}$$

di mana:

- lowcut = 49 Hz
- highcut = 51 Hz
- nyq =  $0.5 \times 200 \text{ Hz} = 100 \text{ Hz}$

Koefisien filter dibangun menggunakan fungsi **butter** untuk mendesain filter Butterworth orde 4.

**b,a=butter(order, [low, high], btype='stop')**

Filter diterapkan dengan menggunakan fungsi **filtfilt** untuk menerapkan filter dua arah, sehingga menghindari pergeseran fasa.

**bandstop\_data=filtfilt(b,a,highpass\_data)**

Setelah ketiga filter diterapkan, sinyal yang sudah difilter divisualisasikan untuk perbandingan dengan sinyal asli, sehingga dapat diamati dampak dari

penerapan filter tersebut. Ini membantu untuk mengetahui seberapa baik filter telah membersihkan sinyal dari noise atau interferensi yang tidak diinginkan.

#### 3.3.2.4. Normalisasi Ulang

Setelah sinyal telah difilter, langkah normalisasi ulang diterapkan. Proses ini penting untuk memastikan bahwa sinyal yang telah difilter tetap berada dalam skala yang seragam (0 hingga 1). Normalisasi ulang memastikan bahwa setiap nilai dalam sinyal yang telah difilter berada dalam rentang yang diinginkan, yang memudahkan perbandingan dan analisis lebih lanjut.

Persamaan untuk normalisasi ulang adalah sama dengan persamaan normalisasi awal:

$$x_{norm, filtered} = \frac{x_{filtered} - x_{min, filtered}}{x_{max, filtered} - x_{min, filtered}}$$

$x_{norm, filtered}$  adalah nilai sinyal yang telah dinormalisasi setelah filtering,

$x_{filtered}$  adalah nilai sinyal setelah filtering,

$x_{min, filtered}$  adalah nilai minimum dari sinyal setelah filtering,

$x_{max, filtered}$  adalah nilai maksimum dari sinyal setelah filtering.

Proses normalisasi ulang dilakukan dengan tujuan untuk memastikan bahwa setiap nilai dalam sinyal yang telah difilter berada dalam rentang yang diinginkan, yang membantu menjaga konsistensi dan stabilitas sinyal selama analisis lebih lanjut.

#### 3.3.2.5. Segmentasi Sinyal

Proses segmentasi sinyal berupa windowing dilakukan sebagai salah satu langkah penting dalam pra-pemrosesan data. Proses ini bertujuan untuk membagi sinyal detak jantung (HRV) yang telah difilter dan dinormalisasi menjadi segmen-segmen kecil dengan ukuran jendela tertentu. Segmentasi ini memungkinkan analisis fitur yang lebih terperinci pada setiap segmen, yang penting untuk meningkatkan akurasi model klasifikasi yang akan digunakan.

Tujuan utama dari proses segmentasi sinyal adalah untuk membagi sinyal panjang menjadi beberapa segmen kecil untuk memudahkan analisis dan ekstraksi fitur, memberikan informasi yang lebih detail dan relevan dari setiap segmen sinyal sehingga meningkatkan kualitas fitur yang diekstraksi, lalu model klasifikasi dapat dilatih dengan data yang lebih bervariasi dan detail sehingga dapat meningkatkan performa model.

Segmentasi sinyal dilakukan dengan menggunakan ukuran jendela tetap. Sinyal HRV yang telah difilter dan dinormalisasi dibagi menjadi beberapa segmen kecil dengan panjang jendela tetap, yaitu 500 sampel per segmen. Fungsi **windowing\_hrv\_data** digunakan untuk membagi sinyal menjadi segmen-segmen kecil. Fungsi ini menerima sinyal HRV dan ukuran jendela sebagai input, dan mengembalikan daftar segmen-segmen sinyal sebagai output.

Hasil dari proses segmentasi ini adalah kumpulan segmen-segmen kecil dari sinyal HRV yang siap untuk dianalisis lebih lanjut. Setiap segmen diperlakukan sebagai unit analisis independen dalam tahap ekstraksi fitur HRV. Proses ini memastikan bahwa setiap bagian dari sinyal HRV dianalisis dengan detail yang memadai, sehingga fitur-fitur yang dihasilkan lebih representatif dan relevan untuk keperluan klasifikasi aktivitas fisik.

### **3.3.3. Tahap Ekstraksi Ciri**

Proses ekstraksi fitur HRV dimulai dengan tahap awal yaitu pemrosesan sinyal detak jantung mentah. Setiap segmen sinyal detak jantung yang direkam direpresentasikan sebagai serangkaian nilai amplitudo yang merekam aktivitas elektrik jantung pada setiap detak. Tahap pertama dalam ekstraksi fitur adalah menghitung metrik-metrik statistik sederhana seperti rata-rata (mean), simpangan baku (standard deviation), RMS (Root Mean Square), kemencengan (skewness), dan kurtosis dari sinyal tersebut. Metrik-metrik ini memberikan gambaran tentang sebaran nilai amplitudo dalam rentang waktu tertentu, yang dapat mencerminkan stabilitas dan distribusi variabilitas interval detak jantung.

Langkah berikutnya adalah identifikasi puncak-puncak dalam sinyal detak jantung menggunakan metode `'find_peaks'`. Proses ini penting karena interval antara puncak-puncak (interval RR) adalah dasar dari analisis HRV. Jarak minimal antara

puncak-puncak ditentukan dengan memperhitungkan frekuensi sampling data untuk memastikan bahwa penghitungan interval RR akurat. Dari interval RR yang dihasilkan, beberapa fitur HRV kunci diekstraksi, seperti rata-rata interval RR, simpangan baku dari interval RR, RMS dari perbedaan interval RR berurutan (RMSSD), serta proporsi perbedaan interval yang melebihi 50 ms (pNN50). Fitur-fitur ini memberikan informasi tentang variabilitas jantung yang berkaitan dengan respons autonom dan kesehatan jantung secara umum.

Selanjutnya, analisis frekuensi dilakukan untuk mengestimasi spektrum daya sinyal detak jantung menggunakan metode Welch. Prosedur ini membagi sinyal menjadi segmen-segmen kecil, menghitung spektrum daya dari masing-masing segmen, dan kemudian mengintegrasikan hasilnya untuk mendapatkan gambaran spektrum daya secara keseluruhan. Estimasi spektrum daya memberikan informasi tentang distribusi daya sinyal dalam domain frekuensi, yang dapat memberikan wawasan tambahan tentang respons fisiologis jantung terhadap aktivitas fisik.

Terakhir, entropi sinyal dihitung untuk menggambarkan tingkat ketidakpastian atau kompleksitas sinyal detak jantung. Entropi digunakan untuk mengevaluasi derajat keacakan atau regularitas sinyal, yang memiliki implikasi terhadap adaptabilitas sistem kardiovaskular terhadap perubahan lingkungan atau kondisi fisik.

Hasil dari seluruh proses ekstraksi fitur HRV ini kemudian diorganisir ke dalam bentuk dataframe menggunakan pustaka pandas di Python. Dataframe ini memuat semua fitur HRV yang telah diekstraksi dari setiap segmen sinyal, dan siap untuk digunakan dalam analisis lebih lanjut serta klasifikasi kondisi fisik berdasarkan karakteristik HRV. Visualisasi dari hasil ekstraksi fitur HRV dapat ditampilkan dalam bentuk tabel pandas, yang memudahkan untuk melihat dan menganalisis data secara komprehensif. Harapannya proses ekstraksi fitur HRV ini dapat menggambarkan variasi detak jantung dalam konteks aktivitas fisik, baik itu saat beristirahat atau berlari.

### **3.3.4. Tahap Pelabelan dan Klasifikasi**

Project ini menggunakan metode klasifikasi dengan Convolutional Neural Network (CNN). CNN adalah jenis jaringan saraf tiruan yang sangat efektif untuk pengenalan pola dan pemrosesan data sekuensial, seperti citra atau sinyal. Dalam konteks ini, CNN

digunakan untuk mengklasifikasikan data fitur Heart Rate Variability (HRV) dari dua kondisi: saat beristirahat (rest) dan saat berlari (run).

Pertama, data HRV dari kedua kondisi ini diimpor dari dua file CSV terpisah, diberi label sesuai kondisi (0 untuk rest dan 1 untuk run), dan kemudian digabungkan menjadi satu dataset. Data ini kemudian dipisahkan menjadi fitur (X) dan label (y), di mana fitur-fitur tersebut dinormalisasi menggunakan StandardScaler untuk meningkatkan performa model.

Setelah itu, data dibagi menjadi set pelatihan dan set pengujian menggunakan fungsi `train_test_split` dari Scikit-learn, dengan proporsi 80% untuk pelatihan dan 20% untuk pengujian. Data fitur diubah bentuknya agar sesuai dengan input yang diharapkan oleh CNN, yaitu dalam bentuk tensor 3 dimensi.

Model CNN yang digunakan memiliki tiga lapisan konvolusi berturut-turut yang masing-masing diikuti oleh fungsi aktivasi ReLU (Rectified Linear Unit) dan lapisan pooling (MaxPool1d) untuk mengurangi dimensi data dan menangkap fitur penting dari sinyal HRV. Setelah lapisan konvolusi, data dilewatkan ke dua lapisan fully connected (lapisan penuh) dengan fungsi aktivasi ReLU dan dropout untuk mencegah overfitting. Lapisan terakhir adalah lapisan output dengan ukuran sesuai dengan jumlah kelas (2 kelas: rest dan run) dan menggunakan fungsi aktivasi softmax untuk menghasilkan probabilitas kelas.

Model ini dilatih menggunakan optimasi Adam dan fungsi loss CrossEntropyLoss. Proses pelatihan dilakukan dalam beberapa epoch dengan ukuran batch 32, dan pada setiap epoch dilakukan forward pass untuk menghitung loss, kemudian backward pass untuk memperbarui bobot melalui optimasi. Model dievaluasi pada set pengujian setelah setiap epoch untuk menghitung validation loss untuk memantau performa model. Mekanisme early stopping digunakan untuk menghentikan pelatihan jika tidak ada peningkatan pada loss validasi setelah beberapa epoch berturut-turut (ditentukan oleh variabel `'patience'`).

Setelah pelatihan selesai, model dievaluasi untuk menghitung akurasi pada set pelatihan dan set pengujian. Evaluasi ini penting untuk memastikan bahwa model tidak hanya belajar dengan baik pada data pelatihan tetapi juga mampu menggeneralisasi dengan baik pada data yang belum pernah dilihat sebelumnya, yaitu data pengujian.

Akurasi dihitung dengan membandingkan prediksi model dengan label sebenarnya. Proses ini melibatkan penggunaan model yang telah dilatih untuk melakukan prediksi pada set data pengujian, dan kemudian menghitung persentase prediksi yang benar dengan membandingkannya dengan label yang sebenarnya.

Kurva loss pelatihan dan validasi diplot untuk memvisualisasikan kinerja model selama pelatihan. Kurva ini membantu dalam memahami bagaimana model belajar seiring waktu dan apakah terdapat masalah seperti overfitting atau underfitting. Dengan memplot kurva loss, kita dapat memantau bagaimana loss pada data pelatihan dan validasi berubah setiap epoch. Idealnya, kedua kurva loss ini akan menurun dan kemudian stabil, menunjukkan bahwa model telah menemukan keseimbangan yang baik antara pelatihan dan generalisasi.

Melalui evaluasi akurasi dan analisis kurva loss, kita dapat menilai seberapa baik model CNN yang dibangun dapat membedakan antara kondisi beristirahat dan berlari berdasarkan fitur HRV. Hal ini memberikan gambaran yang jelas tentang kinerja model dalam tugas klasifikasi yang diinginkan dan menunjukkan potensi penerapannya dalam konteks nyata untuk pemantauan kondisi fisik berbasis HRV.

Selanjutnya hasil prediksi dibandingkan dengan label sebenarnya untuk menghitung *confusion matrix* dan laporan klasifikasi (*classification report*) yang mencakup metrik-metrik seperti precision, recall, dan F1-score. Visualisasi *confusion matrix* juga dibuat menggunakan seaborn untuk memudahkan interpretasi hasil klasifikasi. Dengan seaborn, *confusion matrix* dapat divisualisasikan dalam bentuk *heatmap*, di mana intensitas warna menunjukkan frekuensi prediksi dalam setiap kategori. Visualisasi ini membantu dalam mengidentifikasi pola-pola kesalahan dan memberikan wawasan tambahan mengenai kinerja model. Dengan demikian, kombinasi antara metrik-metrik numerik dan visualisasi grafis menyediakan cara yang komprehensif untuk mengevaluasi dan memahami hasil klasifikasi yang dilakukan oleh model CNN ini.

## **BAB IV**

### **HASIL DAN PEMBAHASAN**

Proses akuisisi data untuk Heart Rate Variability (HRV) menggunakan stetoskop digital dan metode palpasi masing-masing memiliki karakteristik dan keunggulan tersendiri. Stetoskop digital merupakan alat canggih yang memungkinkan pengukuran detak jantung dengan akurasi tinggi. Langkah-langkahnya meliputi persiapan alat dan kalibrasi untuk memastikan akurasi, pengambilan data di mana pasien diminta duduk dalam posisi nyaman, penempatan stetoskop pada titik apeks jantung, rekaman interval RR (interval antara dua detak jantung berturut-turut) yang kemudian diubah menjadi data digital, dan akhirnya analisis data menggunakan software.

Metode palpasi dengan prosesnya yang melibatkan identifikasi lokasi nadi, seperti arteri radial di pergelangan tangan atau arteri karotis di leher, pengukuran manual menggunakan ujung jari telunjuk dan jari tengah untuk merasakan denyut nadi, dan kemudian pencatatan interval RR menggunakan stopwatch atau jam tangan berdetik ini memiliki akurasi dan objektivitas yang lemah dalam menentukan nilai HRV, untuk itu pada proyek ini berfokus pada pengukuran HRV menggunakan stetoskop digital. Sama seperti metode manual, telah didapatkan interval RR persatuan waktu dalam detik yang kemudian diukur, dicatat, dan dianalisis.

Proses akuisisi data untuk Heart Rate Variability (HRV) menggunakan Putty sebagai antarmuka pengambilan data melibatkan beberapa tahapan penting. Pertama, Putty dikonfigurasi dengan perangkat yang mengirimkan data HRV melalui koneksi serial atau jaringan. Untuk koneksi serial, pengaturan termasuk pemilihan port serial yang digunakan (misalnya, COM3) dan parameter seperti baud rate, data bits, stop bits, dan parity sesuai dengan spesifikasi perangkat. Setelah koneksi berhasil, data yang dikirim oleh perangkat akan muncul di jendela terminal Putty, di mana data tersebut direkam menggunakan opsi logging yang disediakan oleh Putty. Data yang direkam ini kemudian disimpan dalam bentuk csv yang dapat dibuka menggunakan teks editor atau spreadsheet untuk pemrosesan lebih lanjut. Data interval RR yang diekstraksi dari csv dianalisis menggunakan software. Software ini menghitung berbagai parameter HRV seperti Mean RR Interval, SDNN, RMSSD, dan pNN50.

Namun, pada proses akuisisi data masih terjadi beberapa kendala. Pertama, perangkat mungkin tidak dapat mengambil data secara real-time, yang dapat mengganggu kontinuitas dan akurasi pengukuran. Ketidakmampuan untuk mengakses data secara langsung membuat penilaian segera dan penyesuaian pengukuran menjadi sulit. Kedua, ketiadaan treadmill menjadi kendala signifikan saat data HRV diambil dalam kondisi pasien sedang beraktivitas fisik terkontrol. Treadmill memungkinkan kontrol terhadap kecepatan yang penting untuk analisis HRV. Tanpa treadmill, sulit untuk menstandarkan tingkat aktivitas fisik, sehingga data yang diperoleh mungkin tidak konsisten atau kurang representatif. Ketiga, pengambilan data di lapangan terbuka rentan terhadap gangguan noise lingkungan, seperti suara angin atau suara lalu lintas, yang dapat mengganggu keakuratan pengukuran HRV. Noise ini dapat menyebabkan grafik yang tidak perlu pada data yang mengharuskan pemrosesan tambahan untuk membersihkan data, menambah kompleksitas dan waktu pemrosesan.

Untuk analisis data yang didapatkan, dapat diketahui bahwa parameter tersebut meliputi Mean RR Interval (rata-rata dari semua interval RR), SDNN (Standard Deviation of NN intervals), RMSSD (Root Mean Square of Successive Differences), dan pNN50 (persentase interval berturut-turut yang berbeda lebih dari 50 ms). Mean RR dihitung dengan mengambil rata-rata dari semua interval RR, SDNN dengan menghitung deviasi standar dari semua interval RR, RMSSD dengan menghitung akar kuadrat dari rata-rata jumlah kuadrat perbedaan interval RR berturut-turut, dan pNN50 dengan menghitung persentase interval berturut-turut yang berbeda lebih dari 50 ms. Data tersebut dapat menunjukkan variabilitas detak jantung dan keseimbangan sistem saraf otonom.


Melalui prosedur yang telah dilaksanakan, didapati data RHR dan HRA yang diperoleh saat naracoba beristirahat dan setelah melakukan aktivitas jogging. Kedua data dihasilkan melalui aktivitas fisik yang dilakukan naracoba. Hal ini dikarenakan aktivitas tersebut memengaruhi kondisi detak jantung seseorang (Muchikenko & Gubasheva, 2021). Besar kedua parameter, RHR dan HRA, didapatkan melalui pengukuran detak jantung tersebut. Dimana sensor akustik yang terdapat pada perangkat ini menangkap suara detak jantung yang kemudian diproses untuk menghitung heart rate (HR) dalam satuan denyut per menitnya (BPM). Selain HR, stetoskop digital kemudian menganalisis variabilitas denyut jantung (HRV) dalam variasi waktu antara detak jantung individu. Analisis HRV ini



kemudian memberikan informasi mengenai sistem kardiovaskular dari naracoba dimana RHR dan HRA memiliki perbedaan nilai HRV yang signifikan.

Berikutnya dilanjut pada tahap pra-pemrosesan data, yang dimulai dengan mengimpor data ke dalam program untuk tahap normalisasi yang dimana amplitudo data yang diambil akan distandarisasi ke dalam range antara 0 hingga 1. Langkah normalisasi ini penting untuk menjaga konsistensi dalam analisis dan meminimalisir dampak variasi amplitudo dari berbagai dataset.


Filtering kemudian dilakukan untuk menyingkirkan noise dan mengisolasi frekuensi relevan dengan berbagai metode filter, diantaranya :Filter Bandpass, dimana memperbolehkan frekuensi dalam rentang tertentu untuk lewat sementara mengurangi frekuensi diluar rentan yang telah ditentukan, sehingga memfokuskan frekuensi yang terkait dengan analisis Heart Rate. Filter Highpass, menyingkirkan frekuensi rendah dari sinyal. Filter Bandstop, menekan rentan kecil antara frekuensi yang seringkali dianggap sebagai noise. Sehingga memperbaiki rasio signal-to-noise. Sebelum dilakukan tahap normalisasi lagi. Berikut ditampilkan perbandingan sinyal denyut jantung salah satu naracoba sebelum dan setelah difilter:



Gambar 4.1. Sinyal Sebelum dan Sesudah Normalisasi dan Filtering

Hasil Sinyal normalisasi sebelum dan sesudah filtering, memperlihatkan adanya perbaikan dalam noise dan peningkatan kualitas sinyal. Dan bisa dikatakan telah berhasil dalam memfilter sinyal data dan menormalisasi ulang data ke dalam range (0-1).

Setelah melalui proses normalisasi dan filtering, sinyal menunjukkan peningkatan yang signifikan dalam kejernihan dan keteraturan. Sinyal awal yang telah dinormalisasi memiliki amplitudo bervariasi antara 0 hingga 1 dengan struktur sinyal yang menunjukkan adanya komponen frekuensi tinggi dan variasi cepat. Hal ini menunjukkan bahwa sinyal tersebut cukup berisik dan kurang jelas dalam hal identifikasi fitur spesifik. Setelah melalui proses filtering menggunakan filter bandpass, highpass, dan bandstop, amplitudo sinyal tetap berada dalam rentang yang sama namun dengan pengurangan signifikan pada komponen frekuensi tinggi. Variasi cepat pada sinyal berkurang, menunjukkan bahwa filter berhasil menghilangkan komponen frekuensi yang tidak diinginkan. Noise yang mengganggu berhasil dikurangi, sehingga fitur penting pada sinyal menjadi lebih jelas. Bentuk gelombang pada sinyal yang telah difilter menjadi lebih halus dan teratur dibandingkan dengan sinyal sebelum difilter, mengindikasikan bahwa komponen frekuensi yang tidak relevan telah diminimalisir. Secara keseluruhan, proses filtering yang diterapkan berhasil membuat sinyal lebih bersih dan mudah untuk dianalisis lebih lanjut.



Gambar 4.2. Grafik FFT Sinyal Ternormalisasi sebelum filtering (a) dan sesudah filtering (b)

Dalam proses plotting sinyal FFT sebelum dan sesudah normalisasi dan filtering, terlihat adanya abnormalitas berupa lonjakan noise yang signifikan di awal data.

Abnormalitas ini bisa disebabkan oleh beberapa faktor utama. Pertama, aplikasi fungsi window yang kurang tepat atau bahkan tidak menggunakan fungsi window sama sekali dapat menyebabkan efek kebocoran spektral (spectral leakage). Kebocoran spektral terjadi ketika sinyal yang dianalisis tidak kontinu pada batas segmen FFT, yang menyebabkan energi frekuensi tersebar ke frekuensi lain, menghasilkan lonjakan tidak diinginkan pada spektrum frekuensi.

Kedua, parameter FFT seperti sampling rate dan panjang FFT yang tidak sesuai dengan karakteristik sinyal juga dapat berkontribusi terhadap masalah ini. Sampling rate yang tidak tepat dapat menyebabkan informasi frekuensi tidak terwakili dengan baik, sedangkan panjang FFT yang tidak sesuai dapat menghasilkan resolusi frekuensi yang tidak memadai. Misalnya, penggunaan sampling rate yang terlalu rendah mungkin tidak menangkap detail penting dari sinyal, sementara panjang FFT yang terlalu pendek mungkin tidak memberikan gambaran spektral yang lengkap.

Ketiga, segmentasi sinyal yang kurang sebelum mengaplikasikan FFT juga dapat menyebabkan lonjakan abnormal pada spektrum frekuensi. Jika sinyal tidak dibagi menjadi segmen-segmen yang tepat atau tidak ada overlapping antara segmen-segmen tersebut, informasi transien (perubahan mendadak pada sinyal) dapat mendominasi spektrum frekuensi. Hal ini sering kali terlihat sebagai lonjakan di awal grafik FFT.

Keempat, efek transien pada sinyal dapat menyebabkan komponen frekuensi tinggi dan rendah yang tidak diinginkan muncul pada hasil FFT. Efek transien ini bisa berasal dari perubahan mendadak pada amplitudo sinyal atau dari adanya sinyal impuls yang singkat namun kuat. Transien ini memperkenalkan komponen frekuensi yang tidak berhubungan dengan sinyal asli yang diinginkan.

Kelima, kesalahan dalam koding juga bisa menjadi penyebab abnormalitas ini. Misalnya, tidak menghapus komponen DC sebelum melakukan FFT dapat menyebabkan puncak besar di frekuensi nol, atau penggunaan parameter filter yang salah dapat mengintroduksi noise tambahan ke dalam sinyal. Kesalahan dalam normalisasi data juga dapat menyebabkan distribusi amplitudo yang tidak merata, mempengaruhi hasil FFT.

Secara keseluruhan, untuk menghindari abnormalitas pada grafik FFT, penting untuk memastikan bahwa langkah-langkah pra-pemrosesan seperti penggunaan fungsi window, pemilihan parameter FFT yang tepat, segmentasi sinyal yang memadai, dan normalisasi data

dilakukan dengan benar. Hal ini akan membantu menghasilkan analisis spektrum frekuensi yang lebih akurat dan representatif, sehingga informasi yang diperoleh dari FFT benar-benar mencerminkan karakteristik sinyal asli.

Selanjutnya adalah memasuki tahapan ekstraksi ciri atau ekstraksi fitur. Ekstraksi fitur dilakukan dengan beberapa parameter yang akan dikalkulasikan ke dalam hasil keluaran sinyal yang diperoleh. Fungsi `extract hrv features` digunakan untuk mengambil sinyal detak jantung dan frekuensi sampling sebagai input, kemudian menghitung berbagai metrik statistik dan fitur HRV baik dalam domain waktu maupun frekuensi, serta entropi sinyal. Fitur-fitur ini dapat digunakan untuk analisis lebih lanjut atau untuk digunakan dalam model pembelajaran mesin yang berkaitan dengan analisis detak jantung. Fitur-fitur tersebut dikelompokkan menjadi fitur ekstraksi sederhana dan RR interval yang berguna untuk menghitung R-R jarak puncak. Berikut adalah beberapa fitur yang digunakan dalam penelitian kali ini.

- mean: Rata-rata sinyal.
- std: Simpangan baku sinyal.
- rms: Akar rata-rata kuadrat sinyal.
- skew: Kemiringan distribusi sinyal.
- kurtosis: Kepekaan distribusi sinyal.
- mean\_rr: Rata-rata interval RR.
- std\_rr: Simpangan baku interval RR.
- rmssd: Akar rata-rata kuadrat dari selisih interval RR berturut-turut.
- sdsd: Simpangan baku dari selisih interval RR berturut-turut.
- pnn50: Persentase dari interval RR berturut-turut yang berbeda lebih dari 50 ms.
- hr: Detak jantung rata-rata dalam bpm (beat per minute).
- cv\_rr: Koefisien variasi dari interval RR (simpangan baku dibagi dengan rata-rata).

## **Hasil Ekstraksi Fitur RHR**

Hasil Ekstraksi Fitur HRV untuk Semua Data:

	mean	std	rms	skew	kurtosis	mean_rr	std_rr	rmsdd	sdsd	pnn50	hr	cv_rr	total_power	entropy
0	0.443456	0.055235	0.446883	0.054091	3.715788	0.663333	0.098008	0.133838	0.072500	33.333333	90.452261	0.147751	0.003828	6.206733
1	0.443460	0.050912	0.446373	0.078072	3.444119	0.703333	0.128863	0.272787	0.272500	33.333333	85.308057	0.183217	0.003067	6.207942
2	0.443119	0.050900	0.446033	0.106085	3.264139	0.586250	0.038790	0.064936	0.064161	0.000000	102.345416	0.066167	0.003755	6.207946
3	0.443650	0.043566	0.445784	0.138179	3.730144	0.740000	0.083766	0.102774	0.007500	66.666667	81.081081	0.113197	0.002666	6.209756
4	0.443598	0.053480	0.446810	0.151444	3.595875	0.685000	0.096523	0.133135	0.075000	33.333333	87.591241	0.140909	0.004628	6.207268
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
202	0.521391	0.087963	0.528759	0.014627	4.784320	0.675000	0.008165	0.015811	0.015000	0.000000	88.888889	0.012096	0.008973	6.199781
203	0.521482	0.091916	0.529521	-0.001758	4.851660	0.650000	0.024833	0.052559	0.052500	33.333333	92.307692	0.038204	0.008194	6.198316
204	0.521605	0.083705	0.528279	0.027222	5.281206	0.611667	0.010274	0.020616	0.020000	0.000000	98.092643	0.016797	0.008789	6.201215
205	0.521051	0.099000	0.530373	0.018086	6.548029	0.596667	0.010274	0.012748	0.002500	0.000000	100.558659	0.017219	0.010881	6.194949
206	0.521348	0.087769	0.528684	0.048294	5.054304	0.661667	0.032998	0.049497	0.035000	33.333333	90.680101	0.049872	0.008331	6.199839

207 rows x 14 columns

Gambar 4.3 Sebagian Hasil Ekstraksi Fitur RHR

Hasil ekstraksi fitur RHR atau kelompok sampel yang tidak sedang melakukan aktivitas menunjukkan beberapa nilai yang sudah sesuai dengan nilai standar pada umumnya seperti mean, std, dan rms. Namun, dalam pengamatan kali ini beberapa parameter mendapatkan nilai standar yang jauh pada umumnya yaitu nilai skewness, kurtosis, entropy, dan pnn50. Penyebab ketidaksesuaian atau ekstrem dalam nilai-nilai ini bisa berasal dari berbagai faktor, termasuk karakteristik individu subjek, metodologi pengambilan data, serta faktor-faktor lingkungan yang dapat mempengaruhi sistem saraf otonom. Nilai skewness berkisar antara 0.054 hingga 0.151. Skewness mengukur asimetri distribusi data. Nilai skewness yang positif menunjukkan bahwa ekor distribusi lebih panjang di sebelah kanan dari nilai rata-rata, sedangkan nilai negatif menunjukkan ekor distribusi lebih panjang di sebelah kiri. Pada data ini, skewness berkisar dari 0.054 hingga 0.151, yang menunjukkan sedikit ke condongan ke kanan (nilai positif), tetapi masih relatif dekat dengan distribusi normal (skewness idealnya adalah 0). Penyebabnya bisa berasal dari variasi alami dalam sampel data atau karakteristik individual subjek.

Parameter selanjutnya yang perlu ditinjau lebih adalah kurtosis. Nilai kurtosis berkisar antara 3.264 hingga 3.730. Kurtosis mengukur tinggi dan tajamnya puncak distribusi data. Nilai kurtosis yang lebih besar dari 3 menunjukkan distribusi data yang lebih tajam atau berkerucut dibandingkan dengan distribusi normal (kurtosis normal adalah 3). Nilai kurtosis yang tinggi seperti dalam data ini (antara 3.264 hingga 3.730) dapat disebabkan oleh keberadaan outlier atau variasi yang signifikan dalam data HRV subjek tersebut. Parameter ketiga adalah nilai entropy. Pada tabel terlihat Nilai entropy yang cenderung sekitar 6.207 untuk semua sampel. Entropy mengukur kompleksitas atau ketidakpastian dalam data. Nilai entropy yang tinggi menunjukkan data yang lebih kompleks atau tidak teratur. Meskipun nilai

ini tidak ekstrem, memahami apa yang diwakili oleh nilai entropy yang spesifik dalam konteks HRV dapat memerlukan penyesuaian interpretatif berdasarkan studi dan literatur yang relevan. Parameter terakhir yang kurang sesuai yaitu Nilai PNN50 33.33% untuk beberapa sampel. PNN50 mengukur persentase perbedaan antara interval RR yang berbeda lebih dari 50 ms. Nilai ini cukup rendah dibandingkan dengan nilai yang sering kali lebih tinggi pada kondisi istirahat atau non-aktivitas. Hal ini bisa disebabkan oleh variasi individu dalam respons fisiologis terhadap istirahat atau perbedaan dalam cara data HRV diproses atau dihitung.

## Hasil Ekstraksi Fitur HRA

Hasil Ekstraksi Fitur HRV untuk Semua Data:														
	mean	std	rms	skew	kurtosis	mean_rr	std_rr	rmssd	sdsd	pnn50	hr	cv_rr	total_power	entropy
0	0.493786	0.108729	0.505615	-0.022576	1.756775	0.633333	0.098770	0.166433	0.140000	0.000000	94.736842	0.155953	0.015289	6.189165
1	0.492881	0.100407	0.503004	0.000248	1.605541	0.615000	0.086963	0.156285	0.156276	50.000000	97.560976	0.141403	0.013114	6.193096
2	0.493720	0.097109	0.503179	0.107970	1.944310	0.635000	0.089536	0.183371	0.180000	33.333333	94.488189	0.141001	0.011701	6.194732
3	0.493146	0.095887	0.502381	-0.007755	1.673043	0.633333	0.086056	0.151038	0.132500	33.333333	94.736842	0.135877	0.012132	6.195061
4	0.493442	0.094415	0.502393	0.059885	1.819273	0.675000	0.075609	0.102042	0.052500	0.000000	88.888889	0.112013	0.011704	6.195796
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
179	0.535785	0.095409	0.544213	-0.164786	6.014443	0.738333	0.132749	0.224722	0.190000	33.333333	81.264108	0.179795	0.013717	6.197403
180	0.535575	0.097195	0.544323	-0.070886	5.707366	0.693333	0.097411	0.136015	0.080000	33.333333	86.538462	0.140497	0.011351	6.196990
181	0.535737	0.086134	0.542617	-0.041254	4.396953	0.728333	0.150462	0.201556	0.100000	66.666667	82.379863	0.206584	0.010652	6.201163
182	0.535638	0.097734	0.544482	-0.011790	5.511035	0.597500	0.046030	0.060553	0.045461	25.000000	100.418410	0.077037	0.014041	6.196622
183	0.535636	0.091551	0.543404	-0.189053	6.550774	0.735000	0.147366	0.244770	0.202500	33.333333	81.632653	0.200498	0.009300	6.198821

184 rows × 14 columns

Gambar 4.4 Sebagian Hasil Ekstraksi Fitur HRA

Berdasarkan data yang dihasilkan dari ekstraksi fitur, terdapat beberapa parameter HRV yang menunjukkan nilai di luar dari standar umum yang biasanya diamati pada populasi sehat yang melakukan aktivitas. Kelompok parameter ini meliputi RMSSD (Root Mean Square of Successive Differences), PNN50 (Percentage of successive RR intervals that differ by more than 50 ms), dan Total Power. Pertama adalah RMSSD yang dicatat (antara 0.102042 hingga 0.183371 detik atau 102.042 ms hingga 183.371 ms) terlihat lebih tinggi dibandingkan dengan rentang normal yang biasanya berkisar 20 hingga 50 ms. Hal ini mengindikasikan adanya fluktuasi yang sangat besar dalam interval detak jantung berturut-turut dalam jangka pendek. Kemungkinan penyebabnya dapat meliputi variasi respons individu terhadap aktivitas fisik, gangguan teknis selama pengukuran, atau kesalahan dalam pengolahan data. parameter kedua yang kurang sesuai dengan nilai standar adalah PNN50 atau Persentase interval R-R berturut-turut yang berbeda lebih dari 50 ms bervariasi antara 0% hingga 50%. Rentang ini secara signifikan di luar dari nilai normal yang biasanya berkisar antara 2% hingga 35%. Hal ini menunjukkan adanya fluktuasi detak jantung yang tidak konsisten dalam

respons terhadap aktivitas fisik, yang bisa disebabkan oleh faktor individu, kondisi fisik saat pengukuran, atau ketidakstabilan teknis selama pengambilan data. Parameter yang kurang sesuai dalam hasil ekstraksi HRA terakhir adalah nilai Total Power. Rentang nilai Total Power (0.011701 hingga 0.015289) tampak rendah dan mungkin tidak konsisten dengan nilai yang umumnya diamati pada populasi yang sehat, yang biasanya berkisar antara 2000 hingga 4000  $\text{ms}^2$ . Penyebab potensialnya termasuk skala pengukuran yang berbeda, gangguan teknis selama pengukuran, atau karakteristik fisiologis yang unik dari subjek yang diteliti.

Dari hasil pelatihan model CNN untuk klasifikasi data sinyal denyut jantung, diperoleh hasil akurasi pelatihan yang diperoleh adalah sebesar 98.72%. Ini menunjukkan bahwa model CNN sangat baik dalam memprediksi data training. Model mampu mempelajari pola yang ada dalam data training dengan sangat efektif.

Sementara itu, hasil akurasi pengujian yang diperoleh adalah 89.87%. Angka ini menunjukkan seberapa baik model dapat menggeneralisasi dari data yang tidak pernah dilihat sebelumnya (data uji). Akurasi yang tinggi pada data uji menunjukkan bahwa model dapat melakukan prediksi dengan baik pada data baru yang belum pernah dilihat sebelumnya. Meskipun nilai akurasi pengujian juga tergolong tinggi, tetapi lebih rendah dibandingkan dengan akurasi pelatihan. Ini menunjukkan bahwa model masih dapat memprediksi data baru dengan cukup baik, meskipun tidak sebaik pada data training.

Pada pengolahan ini digunakan early stopping. Early stopping digunakan untuk menganalisis sinyal HRV (Heart Rate Variability) dalam pelatihan model machine learning agar mencegah overfitting, yakni situasi ketika model terlalu baik dalam menyesuaikan diri dengan data pelatihan sehingga kinerjanya menurun pada data baru atau data uji. Dalam analisis sinyal ini, early stopping memantau kinerja model pada data validasi selama pelatihan. Jika kinerja pada data validasi berhenti membaik dan mulai menurun setelah beberapa epoch, ini menjadi indikasi bahwa model mulai overfit. Dengan menghentikan pelatihan, model diharapkan memiliki kemampuan generalisasi yang lebih baik. Selain itu, early stopping membantu mengurangi waktu pelatihan dengan menghentikan proses pelatihan ketika tidak ada peningkatan signifikan dalam kinerja model pada data validasi, sehingga sumber daya komputasi dapat digunakan lebih efisien. Di samping itu, early stopping juga membantu dalam menemukan titik optimal di mana model memiliki kompleksitas yang cukup untuk menangkap pola penting tanpa overfitting pada noise. Dengan early stopping, model yang dihasilkan lebih stabil dan dapat diandalkan, karena tidak sensitif terhadap perubahan



kecil dalam data yang dapat mengakibatkan kinerja yang tidak konsisten pada data uji atau data dunia nyata. Model yang dihasilkan juga akan lebih mampu menangkap pola penting yang benar-benar berkaitan dengan variabilitas detak jantung dan kondisi kesehatan terkait, menghasilkan analisis yang lebih akurat dan dapat diandalkan.

```
Epoch [10/100], Training Loss: 0.5060, Validation Loss: 0.4140  
Epoch [20/100], Training Loss: 0.4144, Validation Loss: 0.4798  
Early stopping triggered  
Training Accuracy: 98.72%  
Testing Accuracy: 89.87%
```

Gambat 4.5. Hasil Akurasi Pelatihan dan Pengujian pada Data

Dari hasil dan grafik yang tampil dari proses klasifikasi diketahui bahwa model CNN menunjukkan tanda-tanda overfitting. Overfitting terjadi ketika model terlalu mempelajari data training termasuk noise dan detail-detail yang tidak relevan, sehingga performanya sangat baik pada data training tetapi menurun pada data testing.



Gambat 4.6. Kurva Pembelajaran Model Klasifikasi CNN

Beberapa faktor yang menjadi indikasi terjadinya overfitting pada program adalah adanya perbedaan yang cukup besar antara training accuracy dan testing accuracy (98.72% vs. 89.87%). Indikasi berikutnya adalah model mencapai early stopping pada epoch ke-20, yang berarti model tidak lagi mengalami peningkatan pada validation loss setelah beberapa epoch. Pada awalnya, baik training loss maupun validation loss menurun secara bersamaan hingga sekitar epoch ke-10. Ini menunjukkan bahwa model belajar dengan baik dan

meningkatkan performanya. Setelah epoch ke-10, validation loss mulai mengalami fluktuasi dan tidak menurun secara konsisten. Bahkan ada periode di mana validation loss meningkat, sementara training loss terus menurun. Pada beberapa titik, training loss jauh lebih rendah daripada validation loss, yang merupakan indikasi kuat bahwa model terlalu fit pada data training dan tidak tergeneralisasi dengan baik pada data baru.


Beberapa faktor yang mungkin bisa menjadi penyebab terjadinya overfitting pada program adalah model CNN yang digunakan mungkin terlalu kompleks untuk dataset yang ada, probabilitas dropout yang tidak cukup efektif mengatasi overfitting, atau ukuran dataset mungkin tidak cukup besar untuk kompleksitas model CNN.

Model CNN yang digunakan dalam kasus ini mungkin terlalu kompleks untuk dataset yang tersedia. Kompleksitas model merujuk pada arsitektur dan jumlah parameter dari model tersebut. Model dengan tiga lapisan konvolusi dan jumlah filter yang meningkat di setiap lapisan (16, 32, dan 64) dapat menangkap pola yang sangat rumit dalam data. Namun, jika dataset tidak cukup besar atau beragam, model ini berisiko overfitting, di mana ia mempelajari detail spesifik dan noise dari data training yang tidak relevan untuk data baru.

Meskipun telah diterapkan teknik regularisasi seperti dropout dengan probabilitas 0.5, ini mungkin tidak cukup mengingat tingginya kompleksitas model. Dropout bekerja dengan menghilangkan unit secara acak selama pelatihan untuk memaksa model belajar representasi yang lebih robust. Namun, dengan model yang sangat kompleks, dropout mungkin tidak cukup untuk mengatasi overfitting secara efektif.

Selain itu, ukuran dataset juga memainkan peran penting dalam menghindari overfitting. Dataset yang kecil tidak memberikan cukup data bagi model untuk belajar dan generalisasi dengan baik. Model dengan banyak parameter memerlukan banyak data untuk menangkap pola signifikan dan menghindari pembelajaran noise.

Oleh karena itu, untuk mengatasi masalah ini, bisa dipertimbangkan untuk mengurangi kompleksitas model, meningkatkan dropout rate, dan memperbesar ukuran dataset melalui pengumpulan data tambahan atau menggunakan teknik data augmentation. Dengan penyesuaian ini, model diharapkan mampu mengurangi overfitting dan meningkatkan kemampuan generalisasi pada data baru.



Gambar 4.7. *Confusion Matrix*

Berdasarkan evaluasi performa model klasifikasi menggunakan confusion matrix dan classification report, hasil yang diperoleh menunjukkan bahwa model ini memiliki performa yang baik dalam membedakan antara kondisi "Rest" dan "Run". Dari confusion matrix, model berhasil mengidentifikasi 37 contoh "Rest" dengan benar (True Positives) dan 34 contoh "Run" dengan benar (True Negatives). Namun, terdapat 5 contoh "Rest" yang diprediksi sebagai "Run" (False Positives) dan 3 contoh "Run" yang diprediksi sebagai "Rest" (False Negatives).

	precision	recall	f1-score	support
Rest	0.93	0.88	0.90	42
Run	0.87	0.92	0.89	37
accuracy			0.90	79
macro avg	0.90	0.90	0.90	79
weighted avg	0.90	0.90	0.90	79

Gambar 4.8. *Classification Report*

Secara keseluruhan, model memiliki tingkat keakuratan (accuracy) sebesar 90%, yang mengindikasikan bahwa 90% dari seluruh prediksi model adalah benar. Untuk kelas "Rest", precision mencapai 88%, yang berarti dari seluruh prediksi "Rest", 88% di antaranya adalah benar-benar "Rest". Sementara itu, recall untuk kelas "Rest" sebesar 93%

menunjukkan bahwa model mampu mendeteksi 93% dari seluruh contoh "Rest" yang ada. F1-Score untuk kelas ini adalah 90%, yang merupakan harmonisasi dari precision dan recall.

Untuk kelas "Run", precision mencapai 92%, yang berarti dari seluruh prediksi "Run", 92% di antaranya adalah benar-benar "Run". Recall untuk kelas "Run" sebesar 87% menunjukkan bahwa model mampu mendeteksi 87% dari seluruh contoh "Run" yang ada. F1-Score untuk kelas ini adalah 89%.

Saat melakukan analisis, terdapat beberapa hambatan yang mempengaruhi hasil dan keakuratan. Salah satu hambatan utama adalah keterbatasan alat dan kualitas data. Dalam beberapa tahap ditemukan bahwa sinyal terkontaminasi noise atau adanya missing data yang berujung pada munculnya gap pada sinyal. Hal ini memberikan kendala pada proses analisis dan mengurangi keakuratan hasil. Selain itu, filtering yang tidak tepat kadang menyebabkan distorsi pada sinyal asli, yang kemudian mempengaruhi penghitungan fitur dan analisis selanjutnya. Kemungkinan hambatan lain datang dari proses windowing, yang digunakan untuk membagi sinyal menjadi segmen-segmen kecil. Windowing yang tidak sesuai mengakibatkan beberapa fitur penting dari sinyal terpotong atau tidak terdeteksi dengan sempurna. Ini menyebabkan hilangnya informasi kritis yang penting untuk analisis variabilitas detak jantung atau fitur-fitur sinyal lainnya. Selain itu, proses klasifikasi sinyal juga memungkinkan untuk jadi hambatan jika metode yang digunakan tidak sesuai dengan karakteristik data. Klasifikasi yang kurang cocok berdampak pada rendahnya akurasi dalam mendeteksi pola atau anomali dalam sinyal, yang pada akhirnya mempengaruhi interpretasi hasil dan keputusan yang diambil berdasarkan analisis tersebut.

Secara keseluruhan, tantangan-tantangan ini menunjukkan pentingnya pemilihan metode yang tepat dan pengolahan data yang hati-hati dalam analisis sinyal. Perlunya pemahaman mendalam tentang karakteristik sinyal yang dianalisis, serta penggunaan teknik yang tepat untuk memastikan bahwa data yang dianalisis representatif dan hasil analisisnya akurat untuk memastikan pengolahan sinyal berjalan dengan lancar.

## **BAB V**

### **PENUTUP**

#### **5.1. Kesimpulan**

Berdasarkan percobaan yang telah dilakukan dapat diambil kesimpulan yaitu:

1. Penentuan frekuensi yang harus difilter sangat penting untuk meminimalkan noise pada data HRV. Noise dari lingkungan atau alat ukur dapat mengganggu keakuratan data, sehingga filtrasi yang tepat diperlukan untuk mendapatkan data yang bersih dan akurat. Pada *Bandpass* filter, frekuensi yang ditetapkan yaitu frekuensi *cut off* rendah ( $F_l$ ) yang ditetapkan pada 1 Hz dan frekuensi *cut off* tinggi ( $F_h$ ) yang ditetapkan pada 53 Hz. Filter *highpass* diimplementasikan dengan menggunakan nilai cutoff sebesar 20 Hz. Sementara pada *bandstop* filter, frekuensi yang ditetapkan untuk tahap filtering yaitu pada 49 Hz dan 51 Hz. Pada pengolahan data juga digunakan tahapan normalisasi. Frekuensi normalisasi dihitung dengan membagi frekuensi cutoff dengan frekuensi Nyquist. Frekuensi Nyquist adalah setengah dari frekuensi sampling ( $f_s$ ).
2. Fitur-fitur penting seperti RMSSD, PNN50, dan Total Power berhasil diekstraksi dari data mentah HRV. Fitur-fitur ini memberikan wawasan mendalam tentang variabilitas interval detak jantung dan respons fisiologis terhadap aktivitas fisik.
3. Metode analisis domain waktu, frekuensi, dan nonlinier terbukti efektif dalam mengklasifikasi HRV pada kondisi relaks dan beraktivitas. Analisis ini menunjukkan bahwa metode tersebut dapat memprediksi dengan baik kondisi fisik individu berdasarkan data HRV yang diperoleh. Model CNN menunjukkan akurasi pelatihan yang sangat tinggi tetapi sedikit menurun pada data uji, menunjukkan adanya overfitting. Penggunaan teknik early stopping membantu mengurangi overfitting dan meningkatkan kemampuan generalisasi model.

#### **5.2. Saran**

Berdasarkan kesimpulan diatas, beberapa saran dapat diajukan untuk penelitian lebih lanjut yaitu:

1. Penelitian lebih lanjut perlu dilakukan untuk menentukan frekuensi filtrasi yang paling efektif dalam menghilangkan noise tanpa menghilangkan informasi penting dari sinyal

HRV. Uji berbagai teknik filtrasi dan evaluasi kinerjanya untuk menemukan solusi terbaik.

2. Kembangkan alat pengukur yang dapat mengambil data secara real-time dan lebih tahan terhadap kondisi lingkungan. Teknologi sensor terbaru dan algoritma pengolahan sinyal yang canggih dapat meningkatkan kualitas data yang diperoleh.
3. Perluasan dataset dengan lebih banyak data dan variasi kondisi fisik serta lingkungan dapat membantu mengurangi overfitting. Gunakan teknik data augmentation dan kumpulkan data dari berbagai populasi untuk meningkatkan representasi dataset.
4. Pertimbangkan penggunaan model CNN dengan kompleksitas yang sesuai dengan ukuran dan variasi dataset. Terapkan teknik regularisasi tambahan dan tuning hyperparameter untuk meningkatkan kinerja model.
5. Penggunaan treadmill disarankan untuk standar aktivitas fisik yang lebih konsisten selama pengambilan data HRV, yang memungkinkan pengukuran yang lebih terkontrol dan akurat.
6. Pengambilan data sebaiknya dilakukan di lingkungan yang terkontrol untuk mengurangi noise dan gangguan eksternal, yang akan meningkatkan akurasi dan reliabilitas data yang diperoleh.

## DAFTAR PUSTAKA

- Aubert, A. E., Seps, B., & Beckers, F. (2003). Heart rate variability in athletes. *Sports Medicine*, 33(12), 889-919.
- Bigger, J. T., Fleiss, J. L., Steinman, R. C., Rolnitzky, L. M., Kleiger, R. E., & Rottman, J. N. (1995). Frequency domain measures of heart period variability and mortality after myocardial infarction. *Circulation*, 93(5), 1806-1812.
- Bota, A., Urzeală, C., & Courteix, D. (2019). Heart rate variability—A tool for analysing the autonomic regulation of the cardiac function in sports. *Discobolul*, 57, 23.
- Choi, S., Adnane, M., Lee, G., Jang, H., Jiang, Z., & Park, H. (2010). Development of ECG beat segmentation method by combining lowpass filter and irregular R-R interval checkup strategy. *Expert Syst. Appl.*, 37, 5208-5218. <https://doi.org/10.1016/j.eswa.2009.12.069>.
- Eapen, Z., Turakhia, M., McConnell, M., et al. (2016). Defining a mobile health roadmap for cardiovascular health and disease. *J Am Heart Assoc.*, 5, e003119. doi: 10.1161/JAHA.115.003119.
- Freeman, J. V., Dewey, F. E., Hadley, D. M., et al. (2006). Autonomic nervous system interaction with the cardiovascular system during exercise. *Prog Cardiovasc Dis.*, 48, 342–62. doi: 10.1016/j.pcad.2005.11.003.
- Makivić, B., Nikić Djordjević, M., & Willis, M. S. (2013). Heart Rate Variability (HRV) as a tool for diagnostic and monitoring performance in sport and physical activities. *J. Exerc. Physiol. Online*, 16, 103–131.
- Malik, M., & Camm, A. J. (1995). Heart rate variability. *Clinical Cardiology*, 18(11), 615-620.
- Manser, P., Thalmann, M., Adcock, M., Knols, R., & Bruin, E. (2021). Can Reactivity of Heart Rate Variability Be a Potential Biomarker and Monitoring Tool to Promote Healthy Aging? A Systematic Review With Meta-Analyses. *Frontiers in Physiology*, 12. <https://doi.org/10.3389/fphys.2021.686129>.
- Muzhichenko, M., & Gubasheva, A. (2021). Peculiarity of heart rate variability in students with different intensity of physical load. <https://doi.org/10.36906/FKS-2020/36>.
- Namazi, H. (2021). COMPLEXITY and INFORMATION-BASED ANALYSIS of the HEART RATE VARIABILITY (HRV) while SITTING, HAND BIKING, WALKING, and RUNNING. *Fractals*, 29(5), 1–10. <https://doi.org/10.1142/S0218348X21502017>
- Nayak, S. K., Pradhan, B., Mohanty, B., Sivaraman, J., Ray, S. S., Wawrzyniak, J., Jarzębski, M., & Pal, K. (2023). A Review of Methods and Applications for a Heart Rate Variability Analysis. *Algorithms*, 16(9). <https://doi.org/10.3390/a16090433>
- Peabody, J. E., Ryznar, R., Ziesmann, M. T., & Gillman, L. (2023). A Systematic Review of Heart Rate Variability as a Measure of Stress in Medical Professionals. *Cureus*, 15(1), e34345. doi: 10.7759/cureus.34345.
- Petrowski, K., Herhaus, B., Schöniger, C., Frank, M., & Pyrc, J. (2019). Stress load of emergency service: effects on the CAR and HRV of HEMS emergency physicians on different working days (N = 20). *Int Arch Occup Environ Health*, 92, 155–164.

- Rogers, B., Berk, S., & Gronwald, T. (2022). An Index of Non-Linear HRV as a Proxy of the Aerobic Threshold Based on Blood Lactate Concentration in Elite Triathletes. *Sports*, 10. <https://doi.org/10.3390/sports10020025>.
- Sassi, R., Cerutti, S., Lombardi, F., et al. (2015). Advances in heart rate variability signal analysis: joint position statement by the e-Cardiology ESC Working Group and the European Heart Rhythm Association co-endorsed by the Asia Pacific Heart Rhythm Society. *Europace*, 17, 1341–53.
- Shaffer, F., McCraty, R., & Zerr, C. L. (2014). A healthy heart is not a metronome: an integrative review of the heart's anatomy and heart rate variability. *Frontiers in Psychology*, 5, 1040.
- Stahl, S., An, H., Dinkel, D., Noble, J., & Lee, J. (2016). How accurate are the wrist-based heart rate monitors during walking and running activities? Are they accurate enough? *BMJ Open Sport — Exercise Medicine*, 2. <https://doi.org/10.1136/bmjsem-2015-000106>.
- Tarvainen, M. P., & Niskanen, J. P. (2008). Kubios HRV (version 2.0): user's guide. Kubios HRV Analysis Software.
- Thayer, J. F., Yamamoto, S. S., & Brosschot, J. F. (2010). The relationship of autonomic imbalance, heart rate variability and cardiovascular disease risk factors. *International Journal of Cardiology*, 141(2), 122-131.
- Umetani, K., Singer, D. H., McCraty, R., & Atkinson, M. (1998). Twenty-four hour time domain heart rate variability and heart rate: relations to age and gender over nine decades. *Journal of the American College of Cardiology*, 31(3), 593-601.
- Vitale, J. A., Bonato, M., La Torre, A., & Banfi, G. (2019). Heart rate variability in sport performance: Do time of day and chronotype play a role? *J. Clin. Med.*, 8, 723. doi: 10.3390/jcm8050723.
- Zenati, M. A., Leissner, K. B., Zorca, S., Kennedy-Metz, L., Yule, S. J., & Dias, R. D. (2019). First reported use of team cognitive workload for root cause analysis in cardiac surgery. *Semin Thorac Cardiovasc Surg.*, 31, 394–396.



## LAMPIRAN

1. Tautan folder penyimpanan data mentah hasil akuisisi dari naracoba:  
[https://drive.google.com/drive/folders/1h3eW70aHHsHt\\_WEWttDlja-cmIIzXKts?usp=sharing](https://drive.google.com/drive/folders/1h3eW70aHHsHt_WEWttDlja-cmIIzXKts?usp=sharing)
2. Tautan folder penyimpanan data hasil pemangkasan dan penggantian format menjadi **.txt**:  
<https://drive.google.com/drive/folders/1kS7hvjrZiMQetz1CJxZhAs8PUdPrN36y?usp=sharing>
3. Tautan Google Colaboratory untuk tahap *Pre-processing* dan *Feature Extraction* data denyut jantung naracoba saat kondisi rileks:  
[https://colab.research.google.com/drive/1XYYfJs1K3pnVqjzaelin4V18-nr\\_xV5-?usp=sharing](https://colab.research.google.com/drive/1XYYfJs1K3pnVqjzaelin4V18-nr_xV5-?usp=sharing)
4. Tautan Google Colaboratory untuk tahap *Pre-processing* dan *Feature Extraction* data denyut jantung naracoba saat kondisi setelah berlari:  
<https://colab.research.google.com/drive/1TuUIMC3sv83rAD8-UBUYHRZ3gxMTrGWu?usp=sharing>
5. Tautan Google Colaboratory untuk tahap *labelling* dan klasifikasi data:  
[https://colab.research.google.com/drive/1ZRuC\\_Tx99Fy-350zsZLSi-lhZph0\\_W7M?usp=sharing](https://colab.research.google.com/drive/1ZRuC_Tx99Fy-350zsZLSi-lhZph0_W7M?usp=sharing)