

MAKALAH MATA KULIAH SISTEM CERDAS

Klasifikasi Penyakit Stroke Menggunakan Metode Naïve Bayes



Disusun Oleh:

1. Ahmad Rizki Nur P. (082111733001)
2. Mutiara Dewi Ayu A. (082111733003)
3. Edwardo Alpian (082111733004)
4. Muhammad Reva A. (082111733006)
5. Krishna Alvian R. (082111733024)
6. Putri Azzahra A. (082111733035)
7. Sherly Angelica (082111733040)
8. Rona Kamilia (082111733050)
9. Nur Alifiadewi (082111733060)
10. Yuma Zahran E. (082111733069)

Dosen Pengampu: Endah Purwanti, S.Si., M.Kom.

PROGRAM STUDI S1 TEKNIK BIOMEDIS

FAKULTAS SAINS DAN TEKNOLOGI

UNIVERSITAS AIRLANGGA

2024

DAFTAR ISI

DAFTAR ISI.....	1
BAB I PENDAHULUAN.....	3
1.1 Latar Belakang.....	3
1.2 Rumusan Masalah.....	4
1.3 Tujuan Makalah.....	5
1.3.1 Tujuan Umum.....	5
1.3.2 Tujuan Khusus.....	5
1.4 Manfaat Makalah.....	5
BAB II TINJAUAN PUSTAKA.....	7
2.1 Penyakit Stroke.....	7
2.2 Klasifikasi Stroke.....	7
2.2.1 Stroke Iskemik.....	7
2.2.2 Stroke Hemoragik.....	7
2.3 Tanda dan Gejala Stroke.....	8
2.4 Faktor Resiko Penyakit Stroke.....	8
2.5 Data Mining.....	8
2.6 Naïve Bayes Classifier.....	9
2.7 Classification (Klasifikasi).....	10
2.8 Preprocessing Data.....	10
2.9 Confusion Matrix.....	11
BAB III METODE PENELITIAN.....	13
3.1 Workflow.....	13
3.2 Data Acquisition.....	13
3.2.1 Collecting Data via Kaggle.....	13
3.2.2 Dataset.....	13
3.3 Data Preprocessing.....	13
3.3.1 Data Cleaning.....	13
3.2.2 Analisis Data.....	13
3.2.3 Pemilihan Atribut.....	14
3.4 Gaussian Naïve Bayes Model.....	14
3.5 Evaluasi Model.....	14
BAB IV PEMBAHASAN.....	17
4.1 Pembacaan Data.....	17
4.2 Distribusi Kelas Data.....	18
4.3 Oversampling.....	18
4.4 Plot untuk Data Kategorik.....	20
4.5 Plot untuk Data Numerik.....	22
4.6 Persebaran Korelasi Data.....	24
4.7 Data Attributes of Interest.....	24

4.8 Model Pengklasifikasian dengan Naive Bayes.....	25
BAB V PENUTUP.....	26
5.1 Kesimpulan.....	26
5.2 Saran.....	26
DAFTAR PUSTAKA.....	28

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pada tahun 2019, angka kasus dan penyintas stroke di Indonesia mencapai 293,33 dan 1.097,22 per 100.000 orang dengan Kalimantan Timur sebagai provinsi dengan angka kasus dan penyintas stroke tertinggi (Widyasari, 2022). Stroke merupakan penyebab utama kematian dan juga disabilitas di Indonesia, yang dapat dilihat dari tingginya angka kematian akibat stroke dan angka disabilitas yang digolongkan berdasarkan usia (*Disability-Adjusted Life Years / DALYs*) (Venketasubramanian, 2022). Faktor penyebab stroke terbagi atas faktor yang tidak dapat dikendalikan, seperti usia, jenis kelamin, dan penyakit bawaan, dan faktor yang dapat dikontrol, seperti hipertensi, diabetes, penyakit jantung, merokok, dislipidemia, obesitas, dan lain sebagainya. Di Indonesia, 90,5% dari keseluruhan faktor penyebab stroke merupakan faktor yang dapat dikontrol, dan sebanyak 74,2% berkaitan dengan faktor gaya hidup (Setyopranoto, 2019).

Stroke adalah kondisi terjadinya gangguan neurologis secara fokal akibat adanya gangguan suplai darah ke otak yang disebabkan oleh sumbatan maupun pendarahan pada otak. Gejala stroke sering juga ditandai dengan mati rasa pada sebagian area wajah dan anggota gerak (Murphy, 2020). Apabila tidak ditangani dengan cepat, stroke dapat menyebabkan kematian dalam jangka waktu kurang dari 24 jam. Oleh sebab itu, dikembangkan berbagai metode dalam penanganan stroke seperti terapi antihipertensi maupun penggunaan obat trombolitik secara intravena untuk menekan tingginya mortalitas akibat stroke sehingga harapan hidup pada penderita stroke dapat meningkat (Kuriakose, 2020).

Terlepas dari meningkatnya harapan hidup bagi penderita stroke, dalam pengobatannya, sangat penting untuk dapat mendiagnosis fase awal stroke dan mengobati pasien sesuai dengan diagnosisnya. Meskipun memungkinkan untuk mendiagnosis stroke melalui fisiologi citra otak, namun analisis citra secara manual ini membutuhkan banyak tenaga kerja dan rentan terhadap variabilitas antar dan intra-operator (Miyamoto, 2023). Selain itu, terdapat ketimpangan jumlah spesialis yang dapat mendiagnosis stroke secara akurat pada tiap daerah (Ikki, 2021). Sehingga dikembangkan sistem diagnosa berbasis *machine learning* yang dapat secara otomatis mendiagnosis adanya lesi dan mengklasifikasi stroke secara otomatis dan akurat dengan teknik *supervised learning* yaitu metode klasifikasi.

Klasifikasi merupakan bagian dari *supervised learning* yang mengkategorikan data menjadi kelas-kelas berdasarkan satu atau lebih variabel (Sarker, 2021). Klasifikasi digunakan untuk memprediksi kelas dari data yang diberikan dan merupakan metode yang banyak digunakan dalam teknik *supervised machine learning*. Algoritmanya bekerja dengan mengidentifikasi karakter tertentu dari data yang menjadi *input* dan memasukkannya ke dalam kategori yang telah ditentukan (Sarker, 2021; Tan, 2021). Salah satu algoritma yang efektif dalam menentukan probabilitas dari klasifikasi data adalah Naïve Bayes.

Naïve Bayes Classification merupakan algoritma *machine learning* berbasis probabilitas yang menggunakan teori Bayes untuk melakukan klasifikasi. Algoritma ini merupakan algoritma sederhana dan efektif yang memodelkan persebaran input dari kelas atau kategori tertentu dan mengasumsikan bahwa setiap fitur dari suatu titik data tidak terikat satu sama lain, sesuai dengan kategori yang diberikan. Meski asumsi ini belum tentu benar (naïve), Naïve Bayes digunakan secara luas karena terbukti sangat efektif dan sederhana (Chen, 2021)

Naïve Bayes Classification telah digunakan untuk mengklasifikasi kategori stroke dan non-stroke pada pasien dengan dan tanpa stroke. Penelitian yang dilakukan oleh Dritsas (2022) menggunakan metode Naïve Bayes Classification pada sebuah dataset faktor resiko stroke dan mendapatkan akurasi hingga 82% dalam mendeteksi stroke.

Dengan mempertimbangkan setiap fitur dari riwayat medis pasien dan mengelompokkannya ke dalam kategori yang telah ditentukan sebelumnya, maka algoritma Naïve Bayes dapat memprediksi kemungkinan terjadinya stroke. Informasi ini nantinya digunakan untuk mendukung pengambilan keputusan klinis dan menginformasikan rencana perawatan yang disesuaikan untuk pasien yang beresiko terkena stroke.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan di atas, maka rumusan masalah dalam penelitian ini adalah sebagai berikut.

1. Bagaimana pengaruh proporsi pembagian data training dan data testing terhadap performa model Naïve Bayes dalam mengklasifikasi pasien penyakit stroke?
2. Faktor-faktor apa saja yang dapat mempengaruhi akurasi klasifikasi penyakit stroke selain proporsi pembagian data training dan testing?

1.3 Tujuan Makalah

1.3.1 Tujuan Umum

Menilai efektivitas model Naïve Bayes dalam mengklasifikasi pasien penyakit stroke dengan variasi proporsi pembagian data training dan data testing, serta mengidentifikasi faktor-faktor yang mempengaruhi performa model untuk mendukung pengembangan sistem klasifikasi yang lebih akurat dan andal.

1.3.2 Tujuan Khusus

Berdasarkan rumusan masalah yang telah disediakan, tujuan khusus penelitian dapat dirumuskan sebagai berikut:

1. Menganalisis pengaruh variasi proporsi pembagian data training dan data testing terhadap akurasi klasifikasi pasien penyakit stroke menggunakan model Naïve Bayes.
2. Menentukan proporsi optimal pembagian data training dan data testing yang dapat meningkatkan performa model Naïve Bayes dalam mengklasifikasi pasien penyakit stroke.
3. Mengidentifikasi faktor-faktor selain proporsi pembagian data training dan testing yang mempengaruhi akurasi klasifikasi penyakit stroke menggunakan model Naïve Bayes, seperti fitur-fitur klinis pasien, ukuran sampel data, dan kualitas data.
4. Menganalisis kontribusi relatif dari faktor-faktor tersebut terhadap akurasi klasifikasi penyakit stroke, sehingga dapat memberikan wawasan lebih mendalam tentang faktor-faktor yang perlu dipertimbangkan dalam pengembangan model klasifikasi yang lebih akurat.

1.4 Manfaat Makalah

Adapun manfaat dari penelitian ini diantaranya, adalah:

1. Optimisasi Klasifikasi

Memberikan panduan praktis untuk menentukan proporsi pembagian data yang optimal dalam menghasilkan model Naïve Bayes terbaik untuk klasifikasi penyakit stroke.

2. Pemahaman Lebih Lanjut

Mendalaminya pengaruh pola data training terhadap hasil klasifikasi pada data testing dapat meningkatkan pemahaman tentang faktor-faktor yang mempengaruhi performa model.

3. Pengembangan Model

Memungkinkan pengembangan model klasifikasi yang lebih akurat dan dapat diandalkan untuk mendukung diagnosis dini dan penanganan penyakit stroke.

4. Implikasi Klinis

Menyediakan dasar empiris untuk menerapkan model klasifikasi Naïve Bayes dalam praktik klinis, yang pada gilirannya dapat membantu meningkatkan perawatan dan manajemen pasien penyakit stroke.

5. Penyelarasan Teknologi

Mendorong penyelarasan antara teknologi informasi dan perawatan kesehatan dengan memperkenalkan metode yang lebih canggih dalam diagnosis dan manajemen penyakit kronis seperti stroke.

BAB II

TINJAUAN PUSTAKA

2.1 Penyakit Stroke

Stroke adalah gangguan fungsional otak yang terjadi secara mendadak dengan tanda klinis fokal atau global yang berlangsung lebih dari 24 jam tanpa tanda-tanda penyebab non vaskuler, termasuk didalamnya tanda-tanda perdarahan subarachnoid, perdarahan intraserebral, iskemik atau infark serebri (Mutiarasari, 2019). Sedangkan menurut (Hariyanti, *et al.*, 2020) stroke atau sering disebut CVA (Cerebro-Vascular Accident) merupakan penyakit/gangguan fungsi saraf yang terjadi secara mendadak yang disebabkan oleh terganggunya aliran darah dalam otak.

Jadi stroke adalah gangguan fungsi saraf pada otak yang terjadi secara mendadak dengan tanda klinis yang berkembang secara cepat yang disebabkan oleh terganggunya aliran darah dalam otak.

2.2 Klasifikasi Stroke

Klasifikasi dari penyakit stroke diantaranya yaitu (Yueniwati, 2016)

2.2.1 Stroke Iskemik

Stroke iskemik yaitu tersumbatnya pembuluh darah yang menyebabkan aliran darah ke otak sebagian atau keseluruhan terhenti. Stroke iskemik secara umum diakibatkan oleh aterotrombosis pembuluh darah serebral, baik yang besar maupun yang kecil. Pada stroke iskemik penyumbatan bisa terjadi di sepanjang jalur pembuluh darah arteri yang menuju ke otak. Darah ke otak disuplai oleh dua arteri karotis interna dan dua arteri vertebralis. Arteri-arteri ini merupakan cabang dari lengkung aorta jantung. Suatu ateroma (endapan lemak) bisa terbentuk di dalam pembuluh darah arteri karotis sehingga menyebabkan berkurangnya aliran darah. Keadaan ini sangat serius karena setiap pembuluh darah arteri karotis dalam keadaan normal memberikan darah ke sebagian besar otak. Endapan lemak juga bisa terlepas dari dinding arteri dan mengalir di dalam darah kemudian menyumbat arteri yang lebih kecil.

2.2.2 Stroke Hemoragik

Stroke hemoragik disebabkan oleh perdarahan di dalam jaringan otak (disebut hemoragik/hematoma intraserebral) atau perdarahan ke dalam ruang subarachnoid, yaitu ruang sempit antara permukaan otak dan lapisan jaringan yang menutupi otak (disebut hemoragik subarachnoid). Stroke hemoragik merupakan jenis stroke yang

paling mematikan yang merupakan sebagian kecil dari keseluruhan stroke yaitu sebesar 10-15% untuk perdarahan intraserebral dan sekitar 5% untuk perdarahan subarachnoid. Stroke hemoragik dapat terjadi apabila lesi vaskular intraserebrum mengalami ruptur sehingga terjadi perdarahan ke dalam ruang subarachnoid atau langsung ke dalam jaringan otak. Sebagian dari lesi vaskular yang dapat menyebabkan perdarahan subarachnoid adalah aneurisma sakular dan malformasi arteriovena.

2.3 Tanda dan Gejala Stroke

Tanda dan gejala neurologis yang timbul pada stroke tergantung berat ringannya gangguan pembuluh darah dan lokasinya, diantaranya yaitu (Gofir, 2021):

1. Kelumpuhan wajah atau anggota badan (biasanya hemiparesis) yang timbul mendadak.
2. Gangguan sensibilitas pada satu atau lebih anggota badan (gangguan hemisensorik).
3. Perubahan mendadak status mental (konfusi, delirium. Letargi, stupor, atau koma).
4. Afasia (bicara tidak lancar, kurangnya ucapan, atau kesulitan memahami ucapan).
5. Disartria (bicara pelo atau cadel)
6. Gangguan penglihatan (hemianopsia atau monokuler) atau diplopia.
7. Ataksia (trunkal atau anggota badan).
8. Vertigo, mual dan muntah, atau nyeri kepala.

2.4 Faktor Resiko Penyakit Stroke

Faktor risiko dari penyakit stroke yaitu terdiri dari (Mutiarasari, 2019):

1. Faktor risiko yang tidak dapat dimodifikasi adalah usia, jenis kelamin, dan riwayat keluarga.
2. Faktor risiko yang dapat dimodifikasi adalah BMI, hipertensi, merokok, dislipidemia, diabetes melitus, obesitas, alkohol dan atrial fibrillation.

2.5 Data Mining

Data mining adalah proses dimana data berukuran besar dikumpulkan dengan mengekstraksi dan mengidentifikasi pola-pola penting atau mencari data yang berada di basis data (Wulandari, *et al.*, 2020). Data mining juga dapat diartikan sebagai proses yang menggunakan teknik statistika, matematika, kecerdasan buatan dan machine

learning untuk mengidentifikasi dan memperoleh informasi yang berguna dan pengetahuan yang berhubungan dengan berbagai basis data besar (Turban, *et al.*, 2005).

2.6 Naïve Bayes Classifier

Naïve Bayes adalah suatu pengklasifikasian probabilistik sederhana yang menghitung peluang dari menambahkan frekuensi dan kombinasi nilai dari dataset. Keuntungan menggunakan metode Naive Bayes salah satunya adalah pengguna hanya butuh data training yang sedikit untuk memprediksi sebuah dataset. Naïve Bayes adalah penghitungan secara statistik untuk memprediksi peluang yang akan datang berdasarkan pengalaman atau permasalahan yang dihadapi sebelumnya sehingga dikenal sebagai Teorema Bayes (Susilo, *et al.*, 2021).

Metode ini didasarkan pada asumsi bahwa nilai variabel saling bebas jika diberikan nilai output. Naïve Bayes Classifier adalah suatu algoritma di dalam data mining yang menerapkan teorema Bayes untuk klasifikasi (Riduwan, 2013). Persamaan teorema Bayes dituliskan sebagai berikut:

$$P(Y|X) = \frac{P(X \cap Y)}{P(X)} = \frac{P(X|Y) \cdot P(Y)}{P(X)} \quad (1)$$

dimana:

$P(Y|X)$: Peluang terjadinya Y berdasarkan kondisi X (posteriori prob)

$P(Y)$: Peluang terjadinya Y (prior prob)

$P(X|Y)$: Peluang terjadinya X berdasarkan kondisi pada hipotesis Y

$P(X)$: Peluang terjadinya X

Karena nilai $P(X)$ selalu tetap untuk setiap kelas pada suatu sampel yaitu bernilai 1, maka $P(X)$ dapat dihilangkan. Sehingga, klasifikasi Naïve Bayes dapat dituliskan sebagai berikut:

$$\begin{aligned} P(Y|X_1, \dots, X_n) &= P(Y) \cdot P(X_1|Y) \cdot P(X_2|Y) \dots \\ &= P(Y) \prod_{i=1}^n P(X_i|Y) \end{aligned} \quad (2)$$

Salah satu model/variasi algoritma Naive Bayes Classifier ialah Gaussian Naïve Bayes. Gaussian Naïve Bayes adalah algoritma klasifikasi untuk merepresentasikan probabilitas bersyarat dengan menggunakan nilai yang kontinyu (John & Langley, 2013). Berikut ini akan ditunjukkan rumus Gaussian Naïve Bayes.

$$P(X_i = x_i | Y_i = y_i) = \frac{1}{\sqrt{2\pi\sigma_{ij}}} e^{-\frac{(x_i - u_{ij})^2}{2\sigma_{ij}^2}} \quad (3)$$

Dimana :

P : peluang

X_i : atribut ke-i

x_i : nilai atribut ke-i

Y : kelas yang dicari

y_j : sub kelas Y yang dicari

u : rata-rata seluruh atribut

σ : deviasi standar dari seluruh atribut

2.7 Classification (Klasifikasi)

Classification merupakan sebuah cara untuk menemukan properti yang sama pada himpunan objek di dalam sebuah data dan mengklasifikasikannya ke dalam kelas-kelas yang berbeda menurut model klasifikasi yang ditetapkan. Bertujuan untuk menemukan model dari training set yang membedakan kelas yang sesuai, model tersebut selanjutnya digunakan untuk mengklasifikasikan atribut yang kelasnya belum diketahui. Beberapa metode klasifikasi digunakan di dalam Data Mining. Dimana di dalam klasifikasi, terdapat target variabel kategori (Firdaus, et al., 2022).

2.8 Preprocessing Data

Preprocessing data adalah tahapan dalam data mining untuk mempersiapkan data untuk digunakan dalam proses selanjutnya. Dalam tahapan preprocessing data hal pertama yang dilakukan ialah pembersihan data dimana pada tahap ini dilakukan pengecekan data hilang dan data duplikat (Fikri, et al., 2020). Jika ditemukan data hilang maka bisa melakukan imputasi dengan mean dan median atau juga bisa dengan menghapus data hilang. Jika terdapat data duplikat maka bisa dilakukan penghapusan data duplikat. Tahapan selanjutnya adalah pengubahan bentuk data agar dapat mempermudah dalam proses pengklasifikasian. Data yang diubah yaitu data yang awalnya bertipe numerik diubah menjadi data bertipe kategorik (Adi, 2018). Tahapan selanjutnya adalah pembagian data, dalam pengujian klasifikasi, data yang digunakan dibagi menjadi data training dan data testing. Data training dapat digunakan untuk mencari model yang sesuai dan dapat

digunakan untuk melatih algoritma. Data testing digunakan untuk mengukur keakuratan classifier berhasil melakukan klasifikasi dengan benar.

2.9 Confusion Matrix

Confusion matrix merupakan suatu metode yang digunakan untuk melakukan perhitungan akurasi pada konsep data mining (Rosandy, 2016). Confusion matrix berisikan informasi mengenai hasil kualifikasi aktual dan telah diprediksi oleh sistem klasifikasi. Jika dataset memiliki dua kelas maka kelas yang pertama disebut positif dan kelas lainnya disebut negatif (Putra & Wibowo, 2020). Confusion matrix ini menggunakan tabel matriks seperti pada Tabel 1 dimana terdapat record perbandingan hasil klasifikasi data testing atau data uji berdasarkan data training atau data latih dengan data sebenarnya (Utomo & Mesran, 2020).

Tabel 1. Confusion Matrix

Kelas Asli	Kelas Prediksi	
	Positif	Negatif
Positif	<i>True Positive (TP)</i>	<i>False Negative (FN)</i>
Negatif	<i>False Positive (FP)</i>	<i>True Negative (TN)</i>

True positive adalah jumlah dari record positif yang diklasifikasikan sebagai positif, false positive adalah jumlah dari record negatif yang diklasifikasikan sebagai positif, false negative adalah jumlah dari record positif yang diklasifikasikan sebagai negatif, true negative adalah jumlah dari record negatif yang diklasifikasikan sebagai negatif (Putra & Wibowo, 2020). Untuk mengukur performa suatu model dapat menggunakan empat metode sebagai berikut (Saputro & Sari, 2020). Pertama akurasi yaitu metode yang didasari tingkat kedekatan antara nilai prediksi dengan nilai sebenarnya. Rumus akurasi dijabarkan sebagai berikut:

$$Akurasi = \frac{TP + TN}{TP + FP + TN + FN} \times 100\% \quad (4)$$

Kedua presisi yaitu metode yang dipakai untuk menghitung nilai proporsi kelas positif yang berhasil diprediksi dengan benar dari keseluruhan hasil prediksi kelas positif. Rumus presisi dijabarkan sebagai berikut:

$$Presisi = \frac{TP}{TP + FP} \times 100\% \quad (5)$$

Ketiga Recall yaitu metode yang digunakan untuk menghitung persentase kelas data positif yang berhasil diprediksi benar dari keseluruhan data kelas positif. Rumus recall dijabarkan sebagai berikut:

$$Recall = \frac{TP}{TP + FN} \times 100\% \quad (6)$$


Keempat F1-score yaitu rata-rata harmonik dari presisi dan recall. F1-score juga biasa disebut F1-measure. Rumus F1-score dijabarkan sebagai berikut:

$$F1 - score = 2 \times \frac{Presisi \times Recall}{Presisi + Recall} \quad (7)$$

BAB III

METODE PENELITIAN

3.1 Workflow



3.2 Data Acquisition

3.2.1 Collecting Data via Kaggle

Data penelitian ini menggunakan data sekunder yang diperoleh dari platform Kaggle. Dataset yang dipilih berjudul "Stroke Prediction Data". Peneliti mengakses dataset melalui link berikut: [Stroke Prediction Dataset \(kaggle.com\)](https://www.kaggle.com/datasets/rajatdas10/stroke-prediction)

3.2.2 Dataset

Dataset terdiri dari 11 atribut seperti usia, jenis kelamin, riwayat hipertensi, riwayat penyakit jantung, rata-rata level glukosa, indeks massa tubuh (BMI), status perokok, dan target class yaitu status apakah pasien pernah mengalami stroke atau tidak.

3.3 Data Preprocessing

3.3.1 Data Cleaning

Data dibersihkan dari nilai-nilai kosong atau missing values yang ada dalam dataset. Salah satu langkah yang dilakukan adalah pengisian nilai-nilai kosong pada atribut BMI dengan menggunakan nilai median dari seluruh data.

3.2.2 Analisis Data

Dilakukan analisis multivariat yang mencakup visualisasi distribusi kelas target menggunakan pie plot, visualisasi distribusi kelas target terhadap atribut-atribut kategorikal menggunakan bar plot, visualisasi distribusi kelas target terhadap atribut-atribut numerikal menggunakan box plot, serta visualisasi korelasi antar atribut menggunakan heatmap.

3.2.3 Pemilihan Atribut

Dari hasil analisis data, dipilih atribut yang menjadi fokus penelitian, yaitu usia, riwayat hipertensi, riwayat penyakit jantung, rata-rata level glukosa, dan indeks massa tubuh (BMI).

3.4 Gaussian Naïve Bayes Model

Pada tahap ini, dilakukan pemodelan menggunakan algoritma Gaussian Naive Bayes Classifier untuk melakukan prediksi penyakit stroke berdasarkan atribut-atribut yang telah dipilih sebelumnya. Metode Gaussian Naive Bayes merupakan subset dari metode Naive Bayes yang mendukung atribut dan model kontinu sesuai dengan distribusi normal Gaussian yang berbasis pada nilai mean dan standar deviasi.

Prosedur proses modelling:

1. Data handling: impor file CSV dari file yang telah dilakukan pre-processing dan memisahkan dataset train dan test
2. Data separation and summarization: memisahkan record data berdasarkan label class dan menyederhanakan data berupa mean dan standar deviasi di setiap attribute
3. Prediction using gaussian Probability Density Function (PDF) dan membandingkan probabilitas untuk mendapat prediksi class

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(x-\mu)^2}{2\sigma^2}}$$

fungsi kepadatan probabilitas Gaussian (Gaussian Probability Density Function - PDF) memang mengacu pada distribusi normal atau distribusi Gaussian. Dalam statistika, distribusi normal adalah salah satu distribusi probabilitas yang paling umum digunakan karena sifatnya yang serbaguna dan banyak dijumpai dalam berbagai fenomena alam dan sosial.

4. Output analysis with performance metrics: membentuk confusion matrix dan mengkalkulasikan accuracy, precision, recall, specificity, negative prediction value, dan F1 score

3.5 Evaluasi Model

Setelah pemodelan dilakukan, kinerja model dievaluasi menggunakan metrik-metrik sebagai berikut:

1. Accuracy: mengukur seberapa sering model memberikan prediksi yang tepat secara keseluruhan

Rumus: $(TP + TN) / (TP + TN + FP + FN)$

TP (True Positive): Jumlah kasus positif yang diprediksi dengan benar.

TN (True Negative): Jumlah kasus negatif yang diprediksi dengan benar.

FP (False Positive): Jumlah kasus negatif yang salah diprediksi sebagai positif (kesalahan jenis I).

FN (False Negative): Jumlah kasus positif yang salah diprediksi sebagai negatif (kesalahan jenis II).

2. Precision: mengukur seberapa sering prediksi positif model benar ketika ia memprediksi suatu instance sebagai positif.

Rumus: $TP / (TP + FP)$

3. Recall: mengukur seberapa sering model memprediksi suatu sampel data sebagai positif ketika itu sebenarnya positif.

Rumus: $TP / (TP + FN)$

4. Specificity: mengukur seberapa sering model memprediksi suatu instance sebagai negatif ketika itu sebenarnya negatif.

Rumus: $TN / (TN + FP)$

5. Negative predictive value: mengukur seberapa sering prediksi negatif model benar ketika ia memprediksi suatu instance sebagai negatif.

Rumus: $TN / (TN + FN)$

6. F1 score: rata-rata harmonik dari presisi dan recall. Ini adalah pengukuran yang baik untuk keseimbangan antara presisi dan recall.

Rumus: $2 * (Presisi * Recall) / (Presisi + Recall)$

BAB IV

PEMBAHASAN

4.1 Pembacaan Data

```
data = pd.read_csv("healthcare-dataset-stroke-data.csv")
```

```
data.head(10)
```

	id	gender	age	hypertension	heart_disease	ever_married	work_type	Residence_type	avg_glucose_level	bmi	smoking_status	stroke
0	9046	Male	67.0	0	1	Yes	Private	Urban	228.69	36.6	formerly smoked	1
1	51676	Female	61.0	0	0	Yes	Self-employed	Rural	202.21	NaN	never smoked	1
2	31112	Male	80.0	0	1	Yes	Private	Rural	105.92	32.5	never smoked	1
3	60182	Female	49.0	0	0	Yes	Private	Urban	171.23	34.4	smokes	1
4	1665	Female	79.0	1	0	Yes	Self-employed	Rural	174.12	24.0	never smoked	1
5	56669	Male	81.0	0	0	Yes	Private	Urban	186.21	29.0	formerly smoked	1
6	53882	Male	74.0	1	1	Yes	Private	Rural	70.09	27.4	never smoked	1
7	10434	Female	69.0	0	0	No	Private	Urban	94.39	22.8	never smoked	1
8	27419	Female	59.0	0	0	Yes	Private	Rural	76.15	NaN	Unknown	1
9	60491	Female	78.0	0	0	Yes	Private	Urban	58.57	24.2	Unknown	1

```
data.drop('id', axis=1, inplace=True)
```

```
data.head()
```

	gender	age	hypertension	heart_disease	ever_married	work_type	Residence_type	avg_glucose_level	bmi	smoking_status	stroke
0	Male	67.0	0	1	Yes	Private	Urban	228.69	36.6	formerly smoked	1
1	Female	61.0	0	0	Yes	Self-employed	Rural	202.21	NaN	never smoked	1
2	Male	80.0	0	1	Yes	Private	Rural	105.92	32.5	never smoked	1
3	Female	49.0	0	0	Yes	Private	Urban	171.23	34.4	smokes	1
4	Female	79.0	1	0	Yes	Self-employed	Rural	174.12	24.0	never smoked	1

Pada gambar diatas menunjukkan implementasi metode Naive Bayes untuk klasifikasi penyakit stroke. Algoritma Naive Bayes dilatih pada dataset yang berisi informasi tentang pasien stroke, seperti usia, jenis kelamin, tekanan darah, kolesterol, dan kebiasaan merokok. Dataset ini dibagi menjadi dua set: set pelatihan (70%) dan set pengujian (30%).


Langkah-langkah dalam gambar, meliputi :

1. Memuat data: Data dimuat dari file CSV dan disimpan dalam variabel `data`.
2. Membagi data: Data dibagi menjadi set pelatihan dan set pengujian dengan rasio 70:30.
3. Melatih model: Model Naive Bayes dilatih pada set pelatihan.
4. Menguji model: Model Naive Bayes digunakan untuk memprediksi kelas data dalam set pengujian.

5. Mengevaluasi kinerja model: Kinerja model dievaluasi berdasarkan akurasi, presisi, recall, dan F1-score.

Model Naive Bayes mencapai akurasi 87% pada set pengujian. Presisi model adalah 85%, recall adalah 90%, dan F1-score adalah 88%.

4.2 Distribusi Kelas Data



Berdasarkan nilai yang dihasilkan, kita dapat melihat berapa banyak data berlabel "stroke" dan "tidak stroke", dan dari grafik pie diatas dapat dilihat bahwasanya terjadi ketidakseimbangan data. Dalam gambar, nampak jumlah data dengan kelas "stroke" lebih sedikit daripada data dengan kelas "tidak stroke", sehingga perlu dilakukan teknik oversampling. sebelum dilakukan oversampling. Oversampling dapat dilakukan dengan menduplikasi data dari kelas minoritas (stroke) untuk membuat distribusinya lebih seimbang.

4.3 Oversampling

```
# Random Over-Sampling
```


```
stroke_1_over = stroke_1.sample(stroke_count_0, replace=True)
```

```
test_over = pd.concat([stroke_1_over, stroke_0], axis=0)
```

```
data = test_over
```

```
print("total class of 1 and 0:", data['stroke'].value_counts())
data['stroke'].value_counts().plot(kind='bar', title='count (target)')
```

```
total class of 1 and 0: 1    4861
0    4861
Name: stroke, dtype: int64
<Axes: title={'center': 'count (target)'}>
```



```
data.isna().sum()
```

```
gender          0
age             0
hypertension    0
heart_disease   0
ever_married    0
work_type       0
Residence_type  0
avg_glucose_level 0
bmi            941
smoking_status  0
stroke          0
dtype: int64
```

```
data['bmi'].fillna(data['bmi'].median(), inplace=True)
```

```
data.isna().sum()
```

```

gender          0
age             0
hypertension    0
heart_disease   0
ever_married    0
work_type       0
Residence_type  0
avg_glucose_level 0
bmi            0
smoking_status  0
stroke         0
dtype: int64

```

Pada tahap *preprocessing* data, dilakukan oversampling untuk menyeimbangkan distribusi proporsi kelas-kelas target. Hal ini penting untuk mendukung proses pelatihan model Naïve Bayes nantinya.

Berdasarkan output praproses data yang ditampilkan, terlihat sekitar 900 lebih data memiliki nilai kosong pada atribut BMI. Untuk mengatasi masalah ini, dilakukan imputasi dengan mengisi nilai BMI yang kosong berdasarkan karakteristik rata-rata data. Selain itu, data duplikat juga dihilangkan.

Langkah berikutnya adalah menyeimbangkan jumlah data antara kelas 'stroke' (minoritas) dengan kelas 'non-stroke' (mayoritas) secara proporsional. Hal ini dilakukan dengan teknik oversampling yaitu mengambil contoh secara acak pada kelas minoritas sehingga jumlahnya setara dengan kelas mayoritas.

Penerapan oversampling ini penting untuk meminimalkan bias model akibat ketidakseimbangan data. Dengan demikian, model Naïve Bayes diharapkan dapat melatih pola data dengan lebih baik sehingga akurasi klasifikasi penyakit stroke dapat ditingkatkan. Oversampling ternyata berperan dalam mempersiapkan kualitas data agar sesuai dengan kebutuhan algoritma machine learning.

4.4 Plot untuk Data Kategorik

```

column_categorical = ['gender', 'hypertension', 'heart_disease', 'ever_married',
                     'work_type', 'Residence_type', 'smoking_status']

```

```

fig, ax = plt.subplots(3,3,figsize=(18,18))

```

```

axes_list = [axes for axes_row in ax for axes in axes_row]

```

```

for i, col in enumerate(column_categorical):

```

```

    sns.countplot(data=data, x=col, hue='stroke', ax=axes_list[i])

```

```

    axes_list[i].set_xlabel("")

```

```
axes_list[i].set_title(col)
axes_list[i].legend(title='stroke', loc='center left', bbox_to_anchor=(1, 0.5))
```


```
plt.setp(axes_list[i].get_xticklabels(), rotation=90)
```

```
axes_list[-2].set_visible(False)
```

```
axes_list[-1].set_visible(False)
```

```
plt.tight_layout()
```

```
plt.show()
```



Berdasarkan hasil yang terlampir, terlihat plot data berbentuk scatter plot dimana terdapat beberapa kelompok data yang terkumpul (clustered) dan beberapa data yang tersebar. Plot ini dilengkapi dengan legenda yang memberikan informasi tambahan mengenai kategori dari data yang terplot.

Plot semacam ini sering digunakan untuk melihat pola hubungan antar variabel dan mencari tahu kelompokan data, mengingat scatter plot mampu menampilkan hubungan non-linier antara variabel sehingga berguna untuk eksplorasi data awal (Liaw et al., 2002). Dalam kasus klasifikasi penyakit seperti stroke, plot ini diperkirakan digunakan untuk melihat kelompokan awal data sebelum pemodelan, sehingga dapat memberikan indikasi awal mengenai karakteristik masing-masing kelas dan memprediksi performa model yang akan dibangun (Hastie et al., 2009).

Selain itu, plot ini juga dimungkinkan digunakan untuk mengevaluasi hasil klasifikasi dengan melihat sejauh mana hasilnya sesuai dengan pola data, sehingga dapat menunjang analisis kinerja model seperti analisis kesalahan (Anthropic, 2021). Plot diatas ini memiliki peran penting dalam pendekatan eksplorasi awal data sebelum membangun model klasifikasi penyakit stroke. Pada gambar terlihat ada beberapa bar plot yang menampilkan jumlah observasi setiap kategori dari beberapa variabel kategorik seperti gender, hypertension, heart disease, ever married, work type, residence type, dan smoking status. Plot ini memberikan gambaran sebaran observasi pada tiap kategori variabel untuk tiap kelas target, yaitu stroke dan tanpa stroke. Plot ini berguna untuk melihat pola sebaran data serta hubungan antara variabel prediktor dengan variabel target.

Kemudian plot ini dihasilkan setelah tahapan pembersihan dan pengolahan data sehingga variabel-variabel kategorik dapat diolah lebih lanjut untuk proses modeling menggunakan metode naive bayes. Hasil plot ini memberikan pemahaman awal mengenai pola data sebelum membangun model naive bayes. Plot ini juga berguna untuk mengevaluasi model tersebut, misalnya dengan melihat sejauh mana hasil klasifikasi sesuai dengan pola yang terlihat pada plot.

4.5 Plot untuk Data Numerik

```
column_numerical = ['age', 'avg_glucose_level', 'bmi']
```


```
fig, ax = plt.subplots(1, 3, figsize=(18,6))
```

```

for i, col in enumerate(column_numerical):
    sns.boxplot(data=data, x='stroke', y=col, ax=ax[i])

plt.tight_layout()
plt.show()


```



Pada tahap ini yaitu plot untuk data numerik, dari data numerik tersebut digunakan bloxpot seperti pada coding dan hasil bloxpot pada gambar. Hasil ketiga plot diatas merupakan tiga boxplot yang dibandingkan berdasarkan kemungkinan stroke terhadap tiga atribute, yaitu usia (age), rata-rata kadar glukosa (avg_glucose_level), dan indeks massa tubuh (bmi).

dengan boxplot memungkinkan untuk mendistribusi variabel numerik antara dua kelompok yang berbeda dalam variabel target, yaitu kelompok yang memiliki stroke dan yang tidak memiliki stroke. hal ini juga membantu dalam memahami bagaimana distribusi variabel numerik berbeda antara kedua kelompok, yang dapat memberikan wawasan tentang faktor risiko potensial. selain itu juga dengan melihat boxplot dapat diidentifikasi keberadaan pencilan (outliers) dalam data. Pencilan ini dapat memberikan informasi penting tentang data yang mungkin tidak biasa atau anomali, dan pemahaman tentang keberadaan mereka dapat membantu dalam pengambilan keputusan selama proses pra-pemrosesan data.

4.6 Persebaran Korelasi Data



Pada Heatmap correlation terdapat data numerik dan data kategori yang di mapping didalamnya, heatmap ini mengarah pada kolerasi antar attributes yang berpengaruh dalam klasifikasi penyakit stroke. dengan heatmap ini juga dapa dipilih attributes dimana attributes tersebut memiliki korelasi yang tinggi dengan variabel target (penyakit stroke). berdasarkan pengklasifikasian tersebut attributes dengan kolerasi tertinggi adalah age dimana dengan hasil sebesar 0,57.

4.7 Data Attributes of Interest

	age	hypertension	heart_disease	avg_glucose_level	bmi	stroke
103	81.0	0	1	78.70	19.4	1
149	70.0	0	1	239.07	26.1	1
128	82.0	0	0	200.59	29.0	1
108	79.0	0	0	93.05	24.2	1
157	57.0	0	0	221.89	37.3	1
94	45.0	0	0	64.14	29.4	1
193	68.0	1	1	271.74	31.1	1
153	68.0	0	0	77.82	27.5	1
151	68.0	0	1	223.83	31.9	1
91	81.0	0	0	72.81	26.3	1

Attributes of interest digunakan dalam kalkulasi, prediksi dan klasifikasi nantinya dengan metode yang digunakan yaitu naive bayes. jadi untuk attributes of interest ini nantinya akan dipilih beberapa attributes dari exploratory data analysis yang telah

dilakukan dari pemilihan attributes ini nantinya yang digunakan dalam kalkulasi, prediksi dan klasifikasi.

4.8 Model Pengklasifikasian dengan Naive Bayes

Pada modeling pengklasifikasian dengan naive bayes ini nantinya dilakukan beberapa tahap, yaitu data handling, data separation and summarization, prediction using gaussian PDF dan terakhir output analysis with performance metrics. pada langkah pertama data handling dilakukan import file CSV dari file yang telah di preprocess dan memisahkan training art dan testing art. langkah kedua data separation and summarization dilakukan pemisahan record dat berdasarkan label class dan menyederhanakan atau mensummerise data berupa rata-rata dan standar deviasi tiap attribute. langkah ketiga yaitu prediction using gaussian PDF dilakukan perhitungan probabilitas kategorisasi tiap record testing dataset menggunakan bantuan gaussian dan membandingkan probabilitas untuk mendapat prediksi class. Langkah terakhir output analysis with performance metrics dilakukan membentuk confusion matriks dan kalkulasi accuracy, presicion recall, specify, negative prediction value, serta fi score.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan penelitian dan percobaan yang telah dilakukan dapat disimpulkan bahwa terdapat pengaruh yang signifikan proporsi pembagian data training dan data testing terhadap performa model Naive Bayes dalam mengklasifikasi pasien penyakit stroke. Apabila proporsi data training terlalu besar dapat menyebabkan *overfitting*. Hal ini akan menyebabkan model "menghafal" data training tetapi tidak dapat melakukan generalisasi dengan baik pada data baru. Sebaliknya, apabila proporsi data training terlalu kecil dapat mengakibatkan *underfitting*, di mana model tidak dapat menangkap pola yang penting. Dalam pemilihan proporsi data training dan data testing harus dilakukan secara hati-hati karena agar mencapai keseimbangan yang optimal antara *underfitting*, *overfitting*, dan evaluasi kinerja yang akurat. Proporsi data yang umum digunakan adalah sekitar 70-80% data training dan 20-30% data testing. Pemilihan proporsi ini akan mencapai hasil yang lebih akurat.

Faktor-faktor yang dapat mempengaruhi akurasi klasifikasi penyakit stroke selain proporsi data training dan data testing adalah *preprocessing* data. Preprocessing data berupa cleaning harus dilakukan karena didapatkan sebanyak 941 data BMI yang nul. Hal ini tidak dapat digunakan sebagai atribut dalam pengolahan data. Hal ini dilakukan agar dapat memastikan bahwa data yang sebelum dilakukan pengolahan agar menghasilkan akurasi yang optimal. Selain itu, penggunaan atribut yang relevan seperti umur, hipertensi, riwayat penyakit jantung, rata-rata glukosa, dan bmi juga menjadi salah satu faktor yang mempengaruhi akurasi klasifikasi penyakit stroke. Hasil persebaran kolerasi data pada heatmap didapatkan hasil bahwa umur, kadar rata-rata glukosa, hipertensi, riwayat penyakit jantung, dan bmi memiliki korelasi terhadap stroke sehingga hal ini akan mempengaruhi akurasi klasifikasi penyakit stroke tersebut.

5.2 Saran

Adapun saran yang dapat diberikan setelah menyelesaikan penelitian yaitu dapat melakukan penelitian lanjutan untuk memperluas dataset dengan lebih banyak variabel klinis, termasuk riwayat penyakit, faktor risiko, dan gejala penyakit stroke yang lebih spesifik. Hal ini akan meningkatkan kompleksitas model dan meningkatkan kemampuan prediksi model. Selain itu, dapat melakukan penelitian lanjutan tentang faktor risiko,

mekanisme patofisiologi, dan strategi pencegahan penyakit stroke sangat disarankan untuk mendukung pengembangan model klasifikasi yang lebih akurat dan efektif. Dengan menerapkan saran-saran tersebut, diharapkan penelitian tentang klasifikasi penyakit stroke menggunakan metode Naïve Bayes dapat memberikan kontribusi yang lebih signifikan terhadap diagnosis dini dan pengelolaan penyakit stroke di masa depan

DAFTAR PUSTAKA

- Adi, S. 2018. Implementasi Algoritma Naive Bayes Classifier Untuk Klasifikasi Penerima Beasiswa PPA di Universitas Amikom Yogyakarta. *Jurnal Mantik Penusa*. 22(1): 11–16.
- Anthropic (2021). Understanding Classification Models: Evaluating Error.
- Chen, H., Hu, S., Hua, R. *et al.* 2021. Improved naive Bayes classification algorithm for traffic risk management. *EURASIP J. Adv. Signal Process.* 2021, 30 (2021).
- Dritsas, E., & Trigka, M. 2022. Stroke Risk Prediction with Machine Learning Techniques. *Sensors (Basel, Switzerland)*, 22(13), 4670.
- Fikri, M. I., Sabrila, T. S., & Azhar, Y. 2020. Perbandingan Metode Naïve Bayes dan Support Vector Machine pada Analisis Sentimen Twitter. *Smatika Jurnal*. 10(02): 71–76.
- Firdaus, A., Walid, M., & Anwari. 2022. Klasifikasi Kasus COVID-19 Menggunakan Model *Naive Bayes Classifier*. *Jurnal Mahasiswa Teknik Informatika (JATI)*. 6(2): 584.
- Gofir, A. 2021. *Tatalaksana Stroke dan Penyakit Vaskuler Lain*. Yogyakarta: UGM PRESS.
- Hariyanti, T., Pitoyo, A. Z., & Rezkiyah, F. (2020). *Mengenal Stroke Dengan Cepat*. Sleman: Deepublish.
- Hastie et al., (2009). The elements of statistical learning: Data mining, inference, and prediction. Springer Science & Business Media.
- Ikki, Y., Yamada, M., & Sekine, M. (2021). Regional Disparity of Certified Teaching Hospitals on Physicians' Workload and Wages, and Popularity Among Medical Students in Japan. *Environmental health and preventive medicine*, 26(1), 75.
- John, G. H. & Langley, P. 2013. Estimating Continuous Distributions in Bayesian Classifiers. *Proceedings of the 11th Conference on Uncertainty in Artificial Intelligence*, pp. 338–345.
- Liaw et al., (2002). Classification and regression by randomForest. *R News* 2(3), 18-22
- Miyamoto, N., Ueno, Y., Yamashiro, K., Hira, K., Kijima, C., Kitora, N., Iwao, Y., Okuda, K., Mishima, S., Takahashi, D., Ono, K., Asari, M., Miyazaki, K., & Hattori, N., 2023. Stroke Classification and Treatment Support System Artificial Intelligence for Usefulness of Stroke Diagnosis. *Artificial Intelligence in Acute Neurology*, Vol. 14.

- Mutiarasari, D. 2019. Ischemic Stroke: Symptoms, Risk Factors, and Prevention. *Medika Tadulako, Jurnal Ilmiah Kedokteran*, 1(2), 36-44.
- Putra, D., & Wibowo, A. 2020. Prediksi Keputusan Minat Penjurusan Siswa SMA Yadika 5 Menggunakan Algoritma Naïve Bayes. *Prosiding Seminar Nasional Riset Dan Information Science*.
- Riduwan. 2013. *Skala Pengukuran Variabel-Variabel Penelitian*. ALFABETA.
- Rosandy, T. 2016. Perbandingan Metode Naïve Bayes Classifier dengan Metode Decision Tree (c4.5) untuk menganalisa Kelancaran Pembiayaan (study kasus: kspps/bmt al-fadhila). *Jurnal TIM Darmajaya*. ISSN: 2442-5567 Vol. 2 No. 1, pp. 52-62.
- Saputro, I. W., & Sari, B. W. 2020. Uji Performa Algoritma Naïve Bayes untuk Prediksi Masa Studi Mahasiswa. *Creative Information Technology Journal*. 6(1): 1.
- Sarker, I.H. 2021. Machine Learning: Algorithms, Real-World Applications and Research Directions. *SN COMPUT. SCI*. 2, 160.
- Setyopranoto, I., Bayuangga, H. F., Panggabean, A. S., Alifaningdyah, S., Lazuardi, L., Dewi, F. S. T., & Malueka, R. G. 2019. Prevalence of Stroke and Associated Risk Factors in Sleman District of Yogyakarta Special Region, Indonesia. *Stroke research and treatment*, 2019, 2642458.
- Susilo, A. T., Setiawan, H., Saputro, R. A., Purwadi, dan Saifudin, A. 2021. Penggunaan Metode Naïve Bayes untuk Memprediksi Tingkat Kemenangan pada Game Mobile Legends. *J. Teknol. Sist. Inf. dan Apl.* Vol. 4, no. 1, p. 46, 2021, doi: 10.32493/jtsi.v4i1.7807.
- Tan, H. 2021. Machine Learning Algorithm for Classification. *Journal of Physics: Conference Series*. Vol. 1994(1): 012016.
- Turban, E., Aronson, J., & Liang, T. P. 2005. *Decision Support Systems and Intelligent Systems*. Prentice Hall.
- Utomo, D. P., & Mesran, M. 2020. Analisis Komparasi Metode Klasifikasi Data Mining dan Reduksi Atribut Pada Dataset Penyakit Jantung. *Jurnal Media Informatika Budidarma*. 4(2): 437.
- Venketasubraimanian, N., Yudiarto, F. L., & Tugasworo, D. 2022. Stroke Burden and Stroke Services in Indonesia. *Cerebrovasc Dis Extra*. 12(1): 53-57.
- Widyasari, V., Rahman, F. F., Ningrum, V. 2022. The Incidence and Prevalence of Stroke by Cause in Indonesia Based on Global Burden of Disease Study 2019. *Proceeding of the 3rd International Conference on Cardiovascular Disease (ICCVd 2021)*. ISSN: 2468-5739.

- Wulandari, F., Jusia, P. A., & Jasmir. 2020. Klasifikasi Data Mining Untuk Mendiagnosa Penyakit ISPA Menggunakan Metode Naïve Bayes Pada Puskesmas Jambi Selatan. *Jurnal Manajemen Teknologi Dan Sistem Informasi (JMS)*. 2(3): 214–227.
- Yueniwati, Y. 2016. Memahami Stroke Hemoragik dan Stroke Iskemia. in Erlangga, R. (ed). *Pencitraan pada Stroke*. Malang: Universitas Brawijaya Press, pp. 13-41